

품질 평가 기록

판정 품질, 같은 메모를 다시 넣었을 때의 일관성,
소요 시간과 비용, 화면이 뜨는 속도를 켜 기록

측정 2026-09-30 ~ 2026-10-02
메모 AI가 쓴 합성 기획 메모 8개. 실제 작가 메모로는 아직 재지 않았다.
원본 github.com/b1ueseoyoung/side-project, main 1297bc8

차례

1	성능	2
	요약 · README.md의 '성능' 절	
2	기획 메모 진단: 판정 품질 평가 기준	4
	eval/CRITERIA.md	
3	기준 결과 분석 (2026-09-30)	7
	eval/BASELINE-2026-09-30.md	
4	gpt-6-luna 결과와 Claude 기준선 비교 (2026-09-30)	12
	eval/LUNA-2026-09-30.md	
5	gpt-6-luna 추론 max 재측정: Claude 기준선·luna high와 비교 (2026-10-01)	17
	eval/LUNA-2026-10-01.md	
6	gpt-6-luna 추론 max 반복 측정: 같은 메모를 3회씩 (2026-10-02)	23
	eval/LUNA-2026-10-02-repeat.md	
7	웹 성능 측정 (2026-10-02)	35
	eval/WEB-2026-10-02.md	
8	판정 품질 평가	36
	부록 · eval/README.md	

README.md의 '성능' 절과 eval/ 폴더의 문서 7개를 내용을 고치지 않고 옮겼다. 문서 사이의 링크는 이 PDF 안의 해당 문서로 이어진다. 2026-10-07에 만들었다.

성능

판정 품질, 같은 메모를 다시 넣었을 때의 일관성, 소요 시간, 비용을 합성 메모로 썼고, 화면이 뜨는 속도도 썼다. 실제 작가 메모로는 아직 재지 않았다. 기준은 [eval/CRITERIA.md](#), 실행 방법은 [eval/README.md](#), 결과 분석은 [eval/LUNA-2026-10-01.md](#)에 있다. 같은 메모를 3회씩 다시 켜 결과는 [eval/LUNA-2026-10-02-repeat.md](#), 웹 성능은 [eval/WEB-2026-10-02.md](#)에 있다.

썬 방법

기획 메모 8개를 4쌍으로 만들었다. 각 쌍의 A는 문제가 없는 메모이고, B는 A에 결함 하나를 심은 메모다(설정 충돌, 동기 문장 삭제, 폐기안 표시 삭제, 결말 삭제). 앱과 같은 진단 경로로 메모마다 1회씩 진단해서, 심은 결함을 찾는지와 멀쩡한 대목을 문제 삼지 않는지를 봤다. 하나의 정확도 수치로 합치지 않고 범주별로 따로 썬다.

결과

본 것	Claude Opus 5.5 (썬론 max)	gpt-6-luna (썬론 high)	gpt-6-luna (썬론 max, 배포 중)
소요 시간 중앙값	737초	95초	305초
1회 비용(표준 요금)	기록 없음(구독)	\$0.006	\$0.020
심은 결함을 문제로 판정	3건 중 3	3건 중 2	3건 중 3
지운 내용을 문제로 판정	2건 중 1	2건 중 2	2건 중 2
문제 없는 대목을 통과	5건 중 5	5건 중 4	5건 중 4
정해 둔 근거 문장까지 인용	6건 중 4	6건 중 2	6건 중 2
하면 안 되는 지적	10건 중 0	10건 중 0	10건 중 2
원문에 없는 인용	786개 중 0	606개 중 3	728개 중 1
바꾸지 않은 질문의 답이 쌍 사이에서 달라짐	78개 중 6	78개 중 8	78개 중 3

Claude 기준선은 작성자 맥의 Claude Code 구독으로 돌려서 비용 기록이 없다. 지금 배포한 설정(gpt-6-luna, 썬론 max, 2026-10-01 측정)은 이렇다.

- 8건 모두 성공했다. 6건은 259~322초, 2건은 약 20분 걸렸고, 비용은 1회 평균 \$0.020이다.
- 원문에 없는 인용 1개는 앱이 걸려서 화면에 나오지 않았다.
- '정해 둔 근거 문장까지 인용'에서 빠진 4건은 문제라고 판정은 했지만 근거 인용이 모자랐던 경우다.
- 미리 정한 관문 5개 중 3개를 통과했고, 정해 둔 근거 인용(3건 이상)과 하면 안 되는 지적(1건 이하)은 넘지 못했다.
- 썬론 high와 비교하면 시간과 비용이 약 3배다. high가 놓친 심은 결함 하나를 찾았고 쌍 사이에서 답이 흔들리는 일도 줄었지만, 하면 안 되는 지적은 0건에서 2건으로 늘었다. 이 결과를 확인하고 max로 배포했다. 판정 프롬프트, 규칙, 질문은 이 측정 뒤로 바뀌지 않았다.

같은 메모를 다시 넣으면

배포 설정으로 같은 합성 메모 8개를 3회씩 다시 진단했다(2026-10-02, 24건 모두 성공).

- 같은 메모에서도 23개 질문 중 2~5개의 답이 실행마다 달라졌다(184개 답 중 22개). 14개 질문은 한 번도 갈리지 않았고, 회차 끝 긴장, 설명 분산, 설정 일관성, 버전 정리, 갈등의 크기에서 주로 갈렸다.

- 심은 결함 3건과 지운 내용 2건은 3회 모두 문제로 판정했다. 가장 먼저 고칠 3가지가 3회 모두 같았던 메모는 8개 중 2개다.
- 미리 정한 관문 5개를 모두 통과한 회차는 없었다. 소요 시간 중앙값은 266초, 비용은 1회 평균 \$0.019이고, 24건 중 1건이 약 20분 걸렸다.

읽을 때 주의할 점

- 메모는 AI가 쓴 합성 메모이고 928~1,341자로 짧다. 수천~수만 자인 실제 메모의 성능을 대표하지 않는다.
- 정답 라벨은 AI가 쓴 임시 라벨이고 사람이 아직 검토하지 않았다.
- 결과 표는 조건마다 1회씩만 돌린 것이다. 배포 설정을 3회 더 돌려 보니 같은 조건에서도 값이 달라졌다(정해 둔 근거 인용 6건 중 3~4건, 하면 안 되는 지적 10건 중 1~3건). 그래서 표의 작은 차이를 모델 차이로 읽으면 안 된다. gpt-6-luna의 high와 max는 출력 스키마도 다르다.
- 개성, 장르 재미, 셀링 포인트, 주인공 매력 같은 주관 문항은 채점하지 않았다.

알려진 약점

평가에서 드러났고 아직 고치지 않은 것이다([eval/BASELINE-2026-09-30.md](#)의 F2, F3, F5와 [eval/LUNA-2026-10-02-repeat.md](#)).

- 가장 먼저 고칠 3가지는 중요도 순이 아니다. 고쳐보세요 항목을 먼저, 그다음 조금 더 항목을 넣되, 같은 신호등끼리는 진단 항목 표 순서대로 3개를 자른다. 그래서 표 뒤쪽 항목(예: 결말 방향)은 문제가 있어도 밀려날 수 있다.
- 메모에 없는 것과 메모 안에서 서로 어긋나는 것이 똑같이 고쳐보세요로 표시된다.
- 인용이 원문에 있는지만 확인하고, 그 인용이 판단을 실제로 뒷받침하는지는 확인하지 않는다.
- 버리거나 바꾼 설정이 없는 메모에서도 버전 정리가 고쳐보세요로 자주 나온다(18건 중 14건). 그때마다 가장 먼저 고칠 3가지에 들어갔다.
- 행동 동기는 24건 모두 고쳐보세요였다. 동기 문장이 적힌 메모와 지운 메모를 가르지 못한다.

웹 성능

로그인 없이 열리는 두 화면(로그인, 예시 리포트)을 Lighthouse로 3회씩 잰다(2026-10-02).

- 화면이 멈추는 시간(TBT)은 7ms 이하, 화면이 밀리는 정도(CLS)는 0.085 이하로 12회 모두 낮았다.
- 가장 큰 내용이 뜨는 시간(LCP)의 데스크톱 중앙값은 로그인 0.5초, 예시 리포트 2.0초다.
- 모바일(느린 4G 가정)은 실행에 따라 LCP가 1.5초에서 13초까지 걸렸다. 전송량 2.2MB 중 2.0MB를 차지하는 폰트 파일 때문으로 보이며, 아직 고치지 않았다.

기획 메모 진단: 판정 품질 평가 기준

현재 진단이 어떤 문제를 잘 찾고, 어디서 잘못된 지적을 하는지 재현 가능한 방식으로 확인하기 위한 기준이다. 실행 방법은 [README.md](#)에 있다.

1. 범위

- 보는 것: 앱이 지금 쓰는 프롬프트, 모델 호출, 후처리(`buildReport`)를 그대로 거친 판정.
- 보지 않는 것: 흥행, 투고 성공, 실제 사용자 메모에서의 품질. 합성 메모 결과는 "이런 유형의 문제를 잡는 구조가 동작하는가"까지만 말한다.
- 앱의 판정 로직, 프롬프트, UI는 평가하면서 바꾸지 않는다. 기준 결과를 먼저 확보하고, 수정안은 따로 제안한다.

2. 라벨

라벨	뜻	앱의 예/아니오와의 관계
문제 없음	메모가 질문의 기준을 충족한다	앱이 "예"면 일치
문제 있음	메모 안의 내용이 기준을 어긴다(모순, 양립할 수 없는 설정)	앱이 "아니오"면 일치
정보 부족	판단에 필요한 내용이 메모에 없다. 작품의 결함이라고 단정할 근거는 없다	앱은 "아니오"로만 표현할 수 있다. 이유와 코멘트가 "메모에 없다"고 말하는지를 사람이 본다
해당 없음	질문이 이 메모에 적용되지 않는다	앱에는 표현할 방법이 없다

- 라벨은 앱의 예/아니오와 따로 관리한다(`eval/labels/`). 범주별로 따로 세고, **하나의 정확도 수치로 합치지 않는다**.
- 지금 있는 라벨은 모두 AI가 쓴 **사람 검토 전 임시 라벨**이다. 전문가 정답으로 취급하지 않는다.
- 이번 샘플에는 '해당 없음'인 대상 질문이 없다. 이 범주는 아직 검증되지 않았다.

3. 사실 확인과 주관 판단의 분리

- **사실 확인 문항**: 메모 안에서 확인할 수 있는 것(설정 충돌, 동기 문장이 있는지, 폐기안/최종안 표시, 결말이 있는지). 임시 라벨을 달고 자동으로 집계한다.
- **주관 문항**: `genre_fit.core_fun` (장르 재미), `originality.twist` (개성), `selling_point.clear` (셀링 포인트), `protagonist_appeal.root` (주인공 매력). 라벨을 달지 않는다. 근거가 판단을 뒷받침하는지와 조언이 쓸모 있는지만 사람이 본다. 이 평가로 흥행이나 투고 성공을 검증했다고 말하지 않는다.

4. 평가 항목

항목	질문	자동 집계	사람 검토
문제 탐지	실제로 있는 문제를 찾는가	'문제 있음'·'정보 부족' 대상에서 최종 답이 "아니오"인지, 반드시 찾아야 할 문제의 필수 인용이 근거에 들어갔는지	코멘트가 그 문제를 제대로 설명하는지
오탐	정상 내용이나 의도적 설정을 문제라고 하는가	'문제 없음' 대상에서 "아니오"가 나왔는지, 하면 안 되는 지적의 인용이 "아니오"의 근거나 '어긋나는 설정'에 쓰였는지(의심 건)	의심 건이 실제 오탐인지

항목	질문	자동 집계	사람 검토
근거 정확성	인용이 원문에 있고, 판단을 실제로 뒷받침하는가	원본 응답의 모든 인용을 앱과 같은 QuoteChecker 로 확인해 원문에 없는 인용을 센다. 대상 질문에서 예상 근거가 인용됐는지, 원문에는 있지만 예상 근거가 아닌 인용(예상 밖 인용)을 표시한다	인용이 판단과 관련 있는지. 원문에 있지만 한 무관한 인용이 통과하는지
정보 부족 처리	메모에 없는 내용을 지어내거나 작품의 결함으로 단정하는가	'정보 부족' 대상의 답, 이유·코멘트에 "메모에 없다" 류의 표현이 있는지(휴리스틱), 근거 확인 실패로 "예"가 "아니오"가 된 답과 그 답이 빨강·먼저 고칠 3가지에 들어갔는지	표현이 결함 단정인지, 없는 내용을 지어냈는지
수정 우선순위	중요한 문제가 '먼저 고칠 3가지'에 들어가는가	빨강 항목(목록 순), 고른 3개와 목록상 위치, 목록 순서 그대로인지, 빠진 빨강, 심은 문제가 들어갔는지	고른 3개가 실제로 가장 중요한지
조언의 유용성	어느 부분을 왜 검토해야 하는지 작가가 이해할 수 있는가	없음	1~5점
반복 일관성	같은 입력에서 핵심 판정이 유지되는가	--repeat 3 에서 질문별로 답이 바뀌었는지, 대상 질문이 바뀌었는지. 쌍 비교에서는 바꾼 부분과 무관한 질문의 답이 쌍 사이에서 달라졌는지	바뀐 판정 중 어느 쪽이 맞는지

운영 지표도 함께 기록한다: 소요 시간, 단계별 실패(모델 호출/후처리), 질문 누락·중복, 앱이 뺀 인용 수.

5. 샘플

기획 메모 8개를 4쌍으로 만들었다. 각 쌍은 A에 정해진 치환만 적용해 B를 만들었고, 치환마다 정확히 한 번만 맞는지 확인했다.

쌍	장르	A	B	대상 질문	임시 라벨 A → B	하면 안 되는 지적
p1	로판	설정이 일관됨	죽은 남동생의 학비를 마련하려 하는 명확한 충돌	consistency.no_conflict	문제 없음 → 문제 있음	가명 '엘라', 리나의 정보원 반전을 충돌로 지적
p2	현판	세 핵심 선택마다 동기 문장이 있음	동기 문장 세 개만 지움	motivation.reason	문제 없음 → 정보 부족	작가가 일부러 숨긴 미소의 정체를 동기 누락·충돌로 지적
p3	무협	폐기안과 최종안이 [폐기]/[최종]으로 구분됨	양립할 수 없는 설정을 모두 최종안처럼 적음	versions.separated, consistency.no_conflict	문제 없음 → 문제 있음	(A) 폐기안을 최종 설정과의 충돌로 지적
p4	스릴러	결말이 적혀 있음	결말 줄만 지움	ending.decided	문제 없음 → 정보 부족	여러 사람이 관여한 의도적 설정을 지적, (B) 없는 결말을 지어냄

- 모델 입력(eval/samples/*.json)에는 앱이 받는 장르, 메모, 참고작만 있다. 정답과 결함 설명은 eval/labels/*.json 에만 있다.
- 라벨마다 대상 질문 ID, 예상 판단, 근거 문장, 반드시 찾아야 할 문제, 하면 안 되는 지적, 바꾼 부분 때문에 함께 달라질 수 있는 질문(mayAlsoChange)을 적었다. 쌍 비교는 이 질문들을 빼고 나머지 질문이 흔들리는지 본다.
- p2는 dev/samples 의 대본 샘플 A("남은 날")를 기획 메모 형식으로 다시 썼다. 예전 대본용 11문항 정답표는 쓰지 않고, 현재 23문항 기준으로 라벨을 새로 달았다.

한계: AI가 쓴 합성 메모이고 결함을 뚜렷하게 심었기 때문에 실제보다 판정이 쉽다. 같은 계열 모델이 판정하므로 결과가 실제보다 좋게 나올 수 있다. 메모가 928~1,341자로 짧아서, 수천~수만 자인 실제 메모의 성능을 대표하지 않는다.

6. 실행 조건

- 앱과 같은 경로를 쓴다: `diagnoseDetailed` (OpenAI Responses API background 응답) → `buildReport`. 평가용으로 진단을 따로 구현하지 않는다.
- 실행마다 샘플 ID, 회사, 모델과 추론 설정, 공급자·응답 모델·응답 ID·토큰 사용량·비용, 프롬프트·스키마·판정 규칙 파일 해시와 git 커밋, 모델 원본 응답, 최종 리포트, 원문에 없는 인용, 후처리로 바뀐 판정, 소요 시간, 성공·실패와 오류를 저장한다.
- 결과는 `eval/results/<실행 시각>/`에 저장하고 리포트 DB에는 넣지 않는다. 인증 정보와 환경 변수 값은 저장하지 않고, 오류 문구 속 비밀 값은 가린다.
- 모델 호출이 실패하면 재시도하지 않고 멈춘다. 로그인·사용 한도·네트워크 문제일 가능성이 커서 원인을 보고한다. 후처리 실패 (질문 누락 등)는 결과로 기록하고 다음 샘플로 넘어간다.
- 한 번에 부르는 모델 호출 수는 `--max-calls` (기본 8)를 넘지 못한다. 반복 실행 (`--repeat 3`)은 이 값을 올려야 커진다.
- 실패를 빼고 집계하지 않는다. 표본 수, 계획 건수, 실제 실행 건수, 실패 건수를 항상 함께 적는다.

7. 사람 검토 절차

1. `eval:score`가 만든 `review.csv`를 스프레드시트로 연다. 우선순위 열 1(대상 질문, 하면 안 되는 지적 의심, 근거 확인 실패로 바뀐 답)부터 본다.
2. [검토]라벨확정 : 임시 라벨이 맞는지 정하고, 틀리면 네 라벨 중 하나로 고친다. 두 사람이 따로 채운 뒤 서로 다른 칸을 이야기로 맞추는 것을 권한다.
3. [검토]인용이 판단을 뒷받침 : 예 / 부분 / 아니오. 원문에 있는 문장이어도 판단과 무관하면 "아니오"다.
4. [검토]조언 이해도 : 작가가 어느 부분을 왜 봐야 하는지 알 수 있으면 5, 전혀 모르겠으면 1.
5. 주관 문항은 라벨 칸을 비워 두고 근거와 조언만 평가한다.
6. 확정된 라벨은 `eval/labels/*.json`에 반영하고 `labelStatus`를 "사람 검토 완료"로 바꾼다. 그 전까지는 모든 자동 집계가 임시 라벨 기준이다.

기준 결과 분석 (2026-09-30)

현재 앱(판정 로직·프롬프트·UI 수정 전)으로 합성 기획 메모 8개를 1회씩 진단한 기준 결과다. 기준은 [CRITERIA.md](#), 실행 방법은 [README.md](#)에 있다.

이 결과는 합성 메모 8개에 대한 것이다. 실제 사용자 메모에서 검증한 품질이 아니다. 라벨은 AI가 쓴 사람 검토 전 임시 라벨이고, 샘플마다 1회씩만 돌렸다.

실행 조건과 건수

- 결과 폴더: `eval/results/20260930-011259/`. 자동 집계는 `summary.md`, 사람 검토표는 `review.csv` (184행)에 있다.
- 표본: 샘플 8개 × 1회 = 계획 8건. 실제 실행 8건 중 성공 8건, 실패 0건(모델 호출 실패 0, 후처리 실패 0)이다. 자동 재시도는 없었다.
- 모델: 설정은 `claude-opus-5-5`, 추론 `max`, Claude Code CLI 2.1.284이다. CLI는 사용 모델로 `claude-opus-5-5` 와 함께 `claude-haiku-4-5-20251001` 도 보고했다. CLI 내부의 보조 작업으로 보이지만 확인하지는 않았다.
- 버전: `git 08bd59d` 에 진단 경로를 노출하는 `diagnose.ts`, `llm.ts` 변경만 더한 상태다(판정 로직·프롬프트는 그대로). 시스템 프롬프트 해시 `6e63177dca9e3b84`, `rules.ts da6a55683be26719`, `items.ts 1293e659696d7113`.
- 소요 시간: 합계 6,485초(1시간 48분), 중앙값 737초, 범위 614~1,050초.

결과 요약 (범주별로 따로 셈, 하나의 정확도로 합치지 않음)

항목	결과
대상 질문: 임시 라벨 '문제 없음'	5건 중 앱 "예" 5건
대상 질문: 임시 라벨 '문제 있음'	3건 중 앱 "아니오" 3건 (p1b 설정 일관성, p3b 버전 정리, p3b 설정 일관성)
대상 질문: 임시 라벨 '정보 부족'	2건 중 앱 "아니오" 1건(p4b, 이유에 "메모에 없어요"), "예" 1건(p2b, 짐작으로 채움 → F1)
대상 질문: 임시 라벨 '해당 없음'	0건. 이 범주는 검증하지 못했다
반드시 찾아야 할 문제	6건 중 자동 판정 '찾음' 4건. 못 찾음 2건 중 p2b는 실제 미탐이고, p3b '객잔 이름'은 라벨 한계다(F7)
하면 안 되는 지적	10건 중 자동 적발 0건. 자동으로 볼 수 없는 1건(p4b 결말 제어냄)은 사람이 확인해야 한다. AI가 이유를 읽어 본 바로는 결말을 제어내지 않고 빠진 내용을 나열했다
원문에 없는 인용	원본 응답 인용 786개 중 0개
후처리로 바뀐 답(근거 확인 실패로 예→아니오)	184개 답 중 0개. 동작은 드라이런으로만 확인했다(F4)
먼저 고칠 3가지	8건 모두 목록 순서 그대로 뽑혔다. 7건은 빨강이 3개를 넘어 순서가 결과를 정했다. 심은 문제가 빨강인데 순서 때문에 빠진 경우 1건(p4b 결말)
쌍 비교(무관 질문 흔들림)	4쌍 모두에서 흔들림이 있었다. 비교한 18~21개 질문 중 1~2개씩, 합계 6건(주관 문항 2건 포함)
반복 일관성	측정하지 않았다(<code>--repeat 3</code> 을 켜지 않음)

요청한 네 가지 분석

- 근거 확인 실패로 바뀐 "예→아니오"가 작품의 결함으로 표시되는가: 이번 8건에서는 0건이었다. 모델이 쓴 인용 786개가 모두 원문에 있었다. 하지만 구조상 그렇게 표시된다. 드라이런에서 앱의 실제 후처리(`buildReport`)에 원문에 없는 인용을

넣었더니, 그 항목이 일반 결함과 같은 빨강 "고쳐보세요"가 되었고 먼저 고칠 3가지의 한 자리를 차지했다. 구분할 수 있는 흔적은 이유 앞에 붙는 "메모에서 근거 문장을 확인하지 못해..." 문구뿐이다(F4).

2. **메모에 없는 내용과 실제로 잘못된 내용을 구분하는가:** 신호에서는 구분하지 못한다. 결말을 지운 p4b는 이유와 코멘트에서 "메모에 없어요"라고 정보 부족을 제대로 말했지만, 신호는 모순(p1b, p3b)과 같은 빨강이었다(F5). 동기 문장을 지운 p2b는 아예 과거 설정으로 동기를 짐작해 "예"라고 했다(F1).
3. **먼저 고칠 3가지가 목록 순서의 영향을 받는가:** 그렇다. 8건 모두 빨강 항목을 목록 순서대로 잘랐다. p4b에서는 심은 결말 문제(목록 17번째)가 빨강인데도 앞 순번의 설정 일관성, 행동 동기, 인물 변화에 밀려 빠졌다. 주관 문항인 장르 재미(6번째)는 7/8건에서 한 자리를 차지했다(F3).
4. **원문에 있지만 판단과 무관한 인용도 통과하는가:** 그렇다. p2b의 "예"는 인물 소개의 과거 설정 문장 하나로 통과했다. 원문 존재만 확인하므로 판단을 받쳐 주는지는 걸러지지 않는다(F2). 대상 질문에서 예상 근거 밖의 인용은 10건 중 9건에 1~3개씩 있었다. 대부분은 판단을 보충하는 인용으로 보이지만, 관련성은 `review.csv` 에서 사람이 확인한다.

계획하지 않았지만 찾은 것: 합성 메모 자체의 결함

- **p2(남은 날):** 로그라인은 "학자금 빚에 쫓기는", 인물 메모는 "아버지 병원비로 생긴 빚"이다. 원본 대본 샘플에서 옮겨 올 때 남은 불일치다.
- **p4(물 아래 마을):** 2006년에 만든 댐(20년 전)인데 수위가 "30년 만에" 최저라고 적었다.
- 앱은 p2a, p2b, p4a, p4b 네 실행 모두에서 이 둘을 설정 일관성 "아니오"로 찾았다. 임시 라벨을 쓴 쪽(AI)이 놓친 결함이므로 앱의 오탐이 아니라 탐지로 본다.
- 다만 이 결함이 빨강 한 자리를 차지해 먼저 고칠 3가지와 쌍 비교에 영향을 주었다. 반복 실행 전에 합성 메모를 고치거나 라벨에 반영해야 한다(F7).

실패 사례별 원인과 수정 제안

수정 제안은 앱에 적용하지 않았다. 기준 결과를 확보하는 동안 판정 로직과 프롬프트는 그대로 두었다.

F1. 동기 문장을 지웠는데 "예": 정보 부족을 짐작으로 채움 (p2b)

- **관찰:** `motivation, reason` 의 임시 라벨은 '정보 부족'인데 앱은 "예"(good)라고 답했다. 이유는 "서운을 구하려는 선택은 아버지의 병을 늦게 알아차려 임종을 지키지 못한 과거가 받쳐 주고"였다. 인물 소개의 과거 설정으로 동기를 추론한 것이다. 나머지 두 선택(회수인과 맞서기, 수명 10년 내주기)의 이유는 따지지 않았다. 그래서 심어 둔 문제가 빨강도, 먼저 고칠 3가지도 되지 못했다(미탐).
- **원인:**
 1. 질문 하나("중요한 선택마다 이유가 적혀 있는가?")가 여러 선택을 한꺼번에 묻는다. 모델은 한 선택의 그럴듯한 배경을 찾으면 "예"로 일반화한다.
 2. 후처리는 "예" 답에 원문 인용이 하나 이상 있는지만 본다. 과거 설정 문장 하나로 조건을 채울 수 있다.
 3. 프롬프트의 "짐작으로 채우지 않는다"는 규칙이 "배경에서 추론한 동기"까지 막을 만큼 구체적이지 않다.
- **수정 제안:**
 - 출력 스키마에 선택별 목록을 둔다: {선택 인용, 이유 인용 또는 null}. 이유 인용이 null인 선택이 하나라도 있으면 후처리에서 자동으로 정보 부족으로 표시한다.
 - 프롬프트에 "이유는 선택과 같은 문장이나 바로 앞뒤에 적혀 있어야 한다. 인물 소개의 과거만으로 동기가 있다고 보지 않는다"를 추가한다.

F2. 원문에 있지만 하면 판단과 맞지 않는 인용도 통과 (p2b)

- **관찰:** F1의 "예" 근거로 쓴 "3년 전 아버지의 병을 늦게 알아차려 임종을 지키지 못했다"는 원문에 있는 문장이라 후처리를 통과했다. 하지만 "선택마다 이유가 적혀 있다"는 판단을 받쳐 주지 못한다.
- **원인:** QuoteChecker 는 인용이 원문에 있는지만 확인한다. 인용과 판단의 관련성은 어디에서도 보지 않는다.
- **수정 제안:** 인용마다 무엇을 뒷받침하는지(예: 어떤 선택의 이유인지)를 함께 받는다. 그러면 사람이 검토할 때와 규칙으로 검사할 때 "무엇의 근거인가"를 확인할 수 있다. 관련성 판정을 다른 AI 채점기에 맡기는 방법은 이번 범위에서 제외했다. 그 전까지는 review.csv 의 "[검토]인용이 판단을 뒷받침" 열로 사람이 표본 검토한다.

F3. '먼저 고칠 3가지'가 중요도가 아니라 항목 목록 순서로 정해짐 (p1a)

- **관찰:** p1a의 빨강 4개(장르 재미, 행동 동기, 전환점 이유, 주제 일관성) 가운데 목록 앞쪽 3개가 그대로 뽑혔고, 주제 일관성은 순서 때문에 빠졌다. 8건 모두 이 방식이었고, 7건은 빨강이 3개를 넘었다. p4b에서는 심은 결말 문제(ending, 목록 17번째)가 빨강인데도 설정 일관성·행동 동기·인물 변화에 밀려 빠졌다. 주관 문항인 장르 재미(6번째)는 7/8건에서 한 자리를 차지해, 뒤 순번의 사실 문제(전환점 이유, 갈등의 크기)를 밀어냈다.
- **원인:** rules.ts 가 빨강을 먼저 모은 뒤 같은 색 안에서는 JUDGED_ITEMS 순서로 3개를 자른다. 모순("문제 있음")과 정보 부족, 사실 문항과 주관 문항(장르 재미)을 구분하지 않는다.
- **수정 제안:**
 - 우선순위에 문제 종류를 반영한다. 예를 들어 설정 모순 같은 '문제 있음'을 '정보 부족'과 주관 문항보다 앞에 둔다.
 - 또는 모델이 빨강 항목의 순위와 이유를 함께 내도록 한다.
 - 최소한 축마다 한 개씩 뽑아, 한 축이 세 자리를 다 차지하지 않게 한다.

F4. 근거 확인 실패가 작품의 결함처럼 표시되는 구조 (이번 실측 0건, 드라이런으로 확인)

- **관찰:** 실제 실행 8건에서는 원문에 없는 인용이 없어 이 경로가 한 번도 쓰이지 않았다. 드라이런에서 앱의 buildReport 에 원문에 없는 인용이 달린 "예"를 넣으면, 답이 "아니오"로 바뀌고 항목은 빨강 "고쳐보세요"가 되며 먼저 고칠 3가지에 들어갔다.
- **원인:** rules.ts 가 근거를 확인하지 못한 "예"를 "아니오"로 바꾸고, 신호 계산은 이 "아니오"를 작품의 결함과 똑같이 센다. 화면에서 구분할 수 있는 것은 이유 앞의 안내 문구뿐이다.
- **수정 제안:** 답을 "아니오"로 바꾸지 말고 "확인 필요" 상태(회색)로 둔다. 빨강 집계와 먼저 고칠 3가지에서도 뺀다. 인용이 짧은 메모에서는 거의 틀리지 않았지만, 긴 실제 메모에서는 다시 재 봐야 한다.

F5. 메모에 없는 것과 잘못된 것이 같은 빨강 (p4b)

- **관찰:** 결말 줄을 지운 p4b는 이유와 코멘트에서 "은주가 결국 어떻게 되었는지는 메모에 없어요"라고 정보 부족을 정확히 말했고, 방향도 결말을 지어내지 않고 "결말 메모로 먼저 정해 보면 어떨까요"였다. 그런데 신호는 모순을 찾은 p1b, p3b와 같은 빨강 "고쳐보세요"였다.
- **원인:** 답이 예/아니오 두 가지뿐이라 정보 부족을 "아니오"로만 표현할 수 있고, 신호와 우선순위는 둘을 구분하지 않는다.
- **수정 제안:** 답에 "메모에 없음"을 추가하고(예/아니오/메모에 없음), 화면에서는 "메모에 없어요"라는 다른 표시로 보여 준다. 우선순위에서는 모순보다 뒤에 둔다. F1의 선택별 목록과 함께 쓰면 동기 공백도 이 상태로 모을 수 있다.

F6. 쌍 사이에서 바꾸지 않은 질문도 흔들림

- **관찰:** 바꾼 부분과 무관한 질문의 답이 4쌍 모두에서 달라졌다.
 - p1: 갈등의 크기 예→아니오, 주제 일관성 아니오→예
 - p2: 버전 정리 예→아니오
 - p3: 주인공 매력 아니오→예(주관)
 - p4: 장르 재미 아니오→예(주관), 회차 끝 긴장 아니오→예

p2의 버전 정리는 같은 사실(빛의 출처가 두 곳에서 다름)을 p2a에서는 설정 일관성으로만, p2b에서는 버전 정리로도 지적한 경우다.

- **원인:** 샘플마다 1회씩만 돌려서, 메모를 바꾼 영향인지 실행마다 생기는 흔들림인지 가릴 수 없다.
- **수정 제안:** 앱을 고치기 전에 `--repeat 3` 으로 같은 샘플의 흔들림부터 쟀다. 모델 호출 24회에 약 5시간이 걸린다. 같은 사실을 어느 질문에서 지적할지에 대한 규칙(버전 표시 문제는 `versions`, 내용 모순은 `consistency`)을 프롬프트에 적는 것도 후보다.

F7. 합성 샘플과 임시 라벨의 한계 (앱의 결함이 아님)

- **관찰:**
 - p2 메모의 "학자금 빛"과 "아버지 병원비로 생긴 빛", p4 메모의 "2006년 댐"과 "30년 만의 최저 수위"는 샘플을 쓸 때 의도하지 않은 결함이었다. 앱은 해당 4건 모두에서 이를 찾았지만 임시 라벨에는 없었다.
 - p3b의 '객잔 이름' 필수 인용은 줄거리 문장 하나만 인정했다. 앱은 반대편 근거로 제목("가제: 흑비단객잔")을 인용해 자동 판정이 '못 찾음'이 되었다.
- **수정 제안:**
 - 반복 실행 전에 p2와 p4 메모의 두 결함을 A/B 양쪽에서 똑같이 고친다. 쌍의 차이는 그대로 둔다.
 - 라벨의 필수 인용에 같은 쪽을 가리키는 대체 문장을 여러 개 적을 수 있게 한다.
 - 이 두 가지를 반영할 때도 실행 결과를 보고 라벨을 고쳤다는 기록을 남긴다.

사람이 검토해야 할 라벨

지금 라벨은 전부 AI가 쓴 임시 라벨이다. 아래는 사람이 확정하기 전까지 자동 집계 "일치/불일치"를 정답 판정으로 읽으면 안 되는 이유와 함께 정리한 목록이다.

샘플	질문	임시 라벨	검토 포인트
p1a	<code>consistency.no_conflict</code>	문제 없음	가명 '엘라'(작가 메모로 의도 표시)와 리나의 정보원 반전을 충돌로 보지 않는 것이 맞는지
p1b	<code>consistency.no_conflict</code>	문제 있음	죽은 남동생의 학비라는 충돌이 '명확한 충돌'로 충분한지
p2a	<code>motivation.reason</code>	문제 없음	세 선택의 이유 문장만으로 "선택마다 이유가 적혀 있다"고 볼 수 있는지
p2b	<code>motivation.reason</code>	정보 부족	경계 사례. 기획 메모에서 동기 문장이 없는 것을 '정보 부족'으로 볼지 '문제 있음'으로 볼지. 인물 소개의 과거(아버지 임종)가 동기로 읽힐 여지가 있는지
p3a	<code>versions.separated</code> , <code>consistency.no_conflict</code>	문제 없음	[폐기]/[최종] 표시가 버전 구분으로 충분한지
p3b	<code>versions.separated</code> , <code>consistency.no_conflict</code>	문제 있음	두 질문이 같은 원인(표시 없는 양립 불가 설정)을 두 번 지적하는 것을 허용할지
p4a	<code>ending.decided</code>	문제 없음	결말 줄이 '도달할 지점'으로 충분히 구체적인지
p4b	<code>ending.decided</code>	정보 부족	경계 사례. 투고용 기획서라면 결말이 없는 것 자체를 '문제 있음'으로 볼 수도 있다

함께 확정해야 할 것:

- **하면 안 되는 지적 6종(샘플별 10건):** 각 라벨의 `mustNotFlag`. 특히 p4b의 "없는 결말을 지어냄"은 자동으로 잡을 수 없어 사람만 판단한다.
- **mayAlsoChange 목록:** 바꾼 부분 때문에 함께 달라져도 되는 질문. 이 목록이 넓으면 쌍 비교가 흔들림을 놓치고, 좁으면 적당한 변화를 흔들림으로 쏜다.
- **주관 문항 4개(장르 재미, 개성, 셀링 포인트, 주인공 매력):** 라벨 없이 실행마다 근거와 조언의 유용성만 평가한다.

- **실행 후 드러난 라벨 보완 후보(F7):** p2a-p2b-p4a-p4b의 `consistency.no_conflict` 를 '문제 있음'으로 볼지(의도하지 않은 결함), p3b '객잔 이름'에 제목 문장을 대체 근거로 인정할지. 결과를 보고 고친 라벨이 되므로 사람이 확정한다.
- **대상 밖 19개 질문:** 이번 라벨은 대상 질문만 다뤘다. 나머지 질문의 앱 판정이 맞는지 `review.csv` 의 5순위 행에서 필요한 만큼 표본 검토한다.

실제 메모로 최종 확인할 때 (이번에는 하지 않음)

이번 결과는 합성 메모에 대한 것이고, 실제 사용자 메모에서 품질을 검증한 것이 아니다. 최종 확인용 실제 메모 3~5개는 아래 조건으로 따로 확보한다. 이번에는 실제 메모를 가져오거나 진단하지 않았다.

1. **동의와 보관:** 작가 본인의 동의를 받은 메모만 쓴다. 원문과 결과는 저장소 밖의 비공개 폴더에 두고, 앱 리포트 DB에는 넣지 않는다. 필요하면 인명·지명을 바꾼다.
2. **처음 보는 메모:** 이 앱으로 진단하거나 프롬프트를 고칠 때 참고한 적이 없는 메모여야 한다.
3. **구성:**
 - 장르를 2개 이상 섞는다.
 - 길이를 섞는다. 3천 자 미만 1개와 1만 자 이상 1개를 포함한다.
 - 폐기안이나 남의 피드백이 섞인 러프한 메모를 1개 이상 넣는다.
 - 작가가 이미 알고 있는 실제 문제(설정 충돌, 동기 공백 등)가 있는 메모를 1개 이상 넣는다.
 - 작가가 "여기는 괜찮다"고 보는 부분이 뚜렷한 메모를 1개 이상 넣는다. 오탐을 보기 위해서다.
4. **라벨을 먼저 단다:** 진단 결과를 보기 전에 작가와 다른 한 사람이 각자 23개 질문에 네 라벨을 달고, "가장 먼저 고칠 3가지"를 적는다. 결과를 먼저 보면 거기에 끌려간다.
5. **반복 실행:** 메모마다 `--repeat 3` 으로 돌린다. max 설정은 1회에 10분 넘게 걸리므로, 메모 5개면 15회에 3시간 안팎이다.
6. **보고를 분리한다:** 합성 샘플 결과와 섞지 않고 별도 표로 보고한다. 두 사람 라벨이 서로 다른 질문은 앱 판정을 채점하지 않고 따로 표시한다.

gpt-6-luna 결과와 Claude 기준선 비교 (2026-09-30)

OpenAI Responses API(gpt-6-luna)로 바꾼 진단 경로를 합성 기획 메모 8개로 1회씩 진단한 결과다.

[BASELINE-2026-09-30.md](#)(Claude Opus)와 같은 샘플과 라벨로 비교한다. 기준은 [CRITERIA.md](#), 실행 방법은 [README.md](#)에 있다.

이 결과는 합성 메모 8개에 대한 것이다. 실제 사용자 메모에서 검증한 품질이 아니다. 라벨은 AI가 쓴 사람 검토 전 임시 라벨이고, 두 모델 모두 샘플마다 1회씩만 돌렸다. 그래서 아래 차이 중 어디까지가 모델 차이이고 어디부터가 실행마다 생기는 흔들림인지 가릴 수 없다. 추론 강도도 다르다. Claude 기준선은 추론 max, luna는 high 로 돌렸다.

실행 조건과 건수

- 결과 폴더: eval/results/20260930-085033/. 자동 집계는 summary.md 와 summary.json, 사람 검토표는 review.csv (184행)에 있다. 콘솔 기록은 .omo/evidence/web-diagnosis-openai/task-9-eval-rerun.txt, 관문 계산은 task-9-gate.txt 의 RERUN 절에 있다. 이 두 파일은 커밋하지 않는 로컬 작업 기록이고, 숫자는 커밋된 summary.json 으로 다시 계산할 수 있다.
- 첫 시도: eval/results/20260930-082823/ 은 4번째 실행(p2b)에서 일시적인 네트워크 오류(fetch failed)로 멈췄다. 결과를 확인하는 요청에 재시도를 넣은 뒤 8건을 처음부터 다시 돌렸다. 첫 시도 폴더는 기록으로 남겨 두었고, 이 문서의 숫자에는 넣지 않았다.
- 표본: 샘플 8개 × 1회로 8건을 계획해 8건을 실행했고, 8건 모두 성공했다(모델 호출 실패 0, 후처리 실패 0). 실행 단위의 자동 재시도는 없었다.
- 모델: 설정은 gpt-6-luna, 추론 high, 공급자 openai-responses 이다. 응답이 보고한 실제 모델도 gpt-6-luna 였다.
- 버전: git 881827f 에 커밋하지 않은 src/lib/diagnosis/diagnose.ts (f493042a38e037d6)와 src/lib/llm.ts (5f62f5e52e0ccd78) 변경을 더한 상태다. 시스템 프롬프트 해시 6e63177dca9e3b84, rules.ts da6a55683be26719, items.ts 1293e659696d7113 은 기준선과 같다. 출력 스키마는 761266653eb022df, prompt.ts는 ba411abe54ea2da3 이다.
- 소요 시간: 합계 798초(13분 18초), 중앙값 95초, 범위 90~120초. 기준선은 합계 6,485초, 중앙값 737초, 범위 614~1,050초였다.
- 비용(표준 요금): 합계 \$0.0484, 1회 평균 \$0.0060, 중앙값 \$0.0060, 최대 \$0.0068이다. 토큰은 입력 중앙값 3,803, 출력 중앙값 11,791(추론 토큰 포함)이다. 기준선은 구독 CLI로 돌려 비용 기록이 없다.

결과 요약 (범주별로 따로 셈, 하나의 정확도로 합치지 않음)

항목	Claude 기준선 (max)	gpt-6-luna (high)
실행	8건 중 성공 8	8건 중 성공 8
대상 질문: 임시 라벨 '문제 없음'	5건 중 "예" 5	5건 중 "예" 4. p2a motivation.reason 이 "아니오"
대상 질문: 임시 라벨 '문제 있음'	3건 중 "아니오" 3	3건 중 "아니오" 2. p3b consistency.no_conflict 가 "예"
대상 질문: 임시 라벨 '정보 부족'	2건 중 "아니오" 1(p4b), "예" 1(p2b, F1)	2건 중 "아니오" 2(p2b, p4b)
대상 질문: 임시 라벨 '해당 없음'	0건	0건. 두 모델 모두 검증하지 못했다

항목	Claude 기준선 (max)	gpt-6-luna (high)
반드시 찾아야 할 문제	6건 중 찾음 4	6건 중 찾음 2(p1b, p4b)
하면 안 되는 지적	10건 중 자동 적발 0	10건 중 자동 적발 0. 사람만 판단할 수 있는 1건(p4b 결말 지어냄)은 이유를 보면 결말을 지어내지 않았다
원문에 없는 인용	원본 인용 786개 중 0	원본 인용 606개 중 3(p1a 1, p3b 2)
후처리로 바뀐 답	184개 중 0	184개 중 0
먼저 고칠 3가지	8건 모두 목록 순서대로. 7건은 빨강이 3개 초과	8건 모두 목록 순서대로. 8건 모두 빨강이 6~8개
쌍 비교(무관 질문 흔들림)	4쌍 모두, 합계 6건	4쌍 모두, 합계 8건
반복 일관성	측정하지 않음	측정하지 않음

luna는 기준선보다 약 8배 빨랐다(중앙값 95초와 737초). 대상 질문 10건 중 기준선과 답이 다른 것은 3건이다. p2b는 '정보 부족' 쪽으로 좋아졌고, p2a와 p3b는 라벨과 어긋났다. 빨강은 샘플마다 6~8개로 기준선보다 많아서 '먼저 고칠 3가지'가 목록 순서에 더 크게 좌우된다.

요청한 네 가지 분석

- 근거 확인 실패로 바뀐 "예→아니오"가 작품의 결함으로 표시되는가: 이번에도 0건이었다. 원문에 없는 인용 3개는 있었지만, 그 인용이 달린 답은 다른 인용이 남아 있어서 답이 바뀌지 않았다. 구조는 기준선 F4와 같다.
- 메모에 없는 내용과 실제로 잘못된 내용을 구분하는가: 답으로는 구분했지만 신호로는 구분하지 못한다. p2b와 p4b 모두 "아니오"였고, 이유에 "메모에 설명되지 않아요", "메모에 없어요"를 썼다. 하지만 신호는 두 건 모두 모순과 같은 빨강 fix 다 (F5와 같음).
- 먼저 고칠 3가지가 목록 순서의 영향을 받는가: 그렇다. 8건 모두 빨강을 목록 순서대로 잘랐고, 빨강이 6~8개라 5~6번째 이후는 전부 빠졌다. p4b의 결말(17번째)과 p2b의 행동 동기(10번째)는 심은 문제이고 빨강인데도 빠졌다. 장르 재미는 4/8건에서 한 자리를 차지했다(기준선 7/8).
- 원문에 있지만 판단과 무관한 인용도 통과하는가: 구조는 그대로다(F2). 대상 질문 10건 중 예상 근거 밖 인용이 있는 것은 5건 (p1a 3개, p3a 2개, p2a·p2b·p4a 각 1개)이다. 기준선은 9건이었다. 관련성은 review.csv 에서 사람이 확인한다.

F1~F7 비교

luna 값은 eval/results/20260930-085033/summary.json , 기준선 값은 eval/results/20260930-011259/summary.json 의 같은 필드에서 읽었다.

대상 질문 (targets)

finalAnswer / 먼저 고칠 3(inTopFixes) / 근거 없음으로 바뀜(downgradedForEvidence) 순서다.

샘플	질문	임시 라벨	기준선	luna
p1a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오
p1b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오
p2a	motivation.reason	문제 없음	yes / - / 아니오	no / - / 아니오
p2b	motivation.reason	정보 부족	yes / - / 아니오	no / - / 아니오
p3a	versions.separated	문제 없음	yes / - / 아니오	yes / - / 아니오
p3a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오
p3b	versions.separated	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오

샘플	질문	임시 라벨	기준선	luna
p3b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	yes / - / 아니오
p4a	ending.decided	문제 없음	yes / - / 아니오	yes / - / 아니오
p4b	ending.decided	정보 부족	no / - / 아니오	no / - / 아니오

기준선과 달라진 세 건:

- **p3b 설정 일관성 "예"(미탐):** luna는 "첩자로 길러진 뒤 배신했다는 설정과 우물에서 살아남았다는 과거는 서로 양립할 수 있어요... 누구의 제자도 된 적 없다는 내용도 다른 설정과 정면으로 어긋나지는 않아요"라고 답했다. 반대편 근거 문장을 "그 뒤로 누구의 제자도 된 적 없다."로 옮겨 적었는데, 원문은 "된 적이 없다."라서 원문에 없는 인용으로 버려졌다. 심은 모순을 놓쳤고, 객잔 이름('청운객잔'과 '흑비단객잔')도 인용하지 않았다.
- **p2a 행동 동기 "아니오"(라벨과 불일치):** 첫 시도에 이어 두 번째도 "아니오"였다. 이번에는 주인공의 선택 이유 하나("자신도 빚 때문에 인생을 저당 잡힌 처지라...")를 인용하고도 "서윤이 새벽에 집을 비우는 이유와 주요 선택의 동기는 메모에서 확인되지 않아"라고 했다. 첫 시도의 이유는 조연 미소의 숨긴 목적이었다. 두 번 모두 질문의 범위를 주인공의 선택에서 주요 인물 전체로 넓혀 읽었다.
- **p2b 행동 동기 "아니오"(기준선 F1 개선):** "아버지의 죽음에 대한 후회가 이 선택을 직접 촉발하는지는 메모에 설명되지 않아요"라고 답해, 과거 설정으로 동기를 짐작하지 않았다. 다만 필수 인용 3개 중 "한결은 회수인과 맞서기로 한다."를 빠뜨려 mustFind는 '못 찾음'이다.

반드시 찾아야 할 문제 (mustFind)

샘플	문제	기준선	luna (답, 필수 인용)
p1b	죽은 테오의 학비를 마련하려 함	찾음	찾음 (아니오, 2/2)
p2b	세 선택의 이유가 없음	못 찾음	못 찾음 (아니오, 2/3)
p3b	첩자 설정과 '누구의 제자도 된 적 없음'	찾음	못 찾음 (예, 1/2)
p3b	객잔 이름이 엇갈림	못 찾음(F7 라벨 한계)	못 찾음 (예, 0/2)
p3b	최종·폐기 표시 없음	찾음	못 찾음 (아니오, 0/2)
p4b	결말이 없음	찾음	찾음 (아니오)

p3b 버전 정리는 답("아니오")은 맞지만 필수 인용을 하나도 달지 않아 '못 찾음'이 되었다.

쌍 비교 (pairs)

쌍	기준선: 달라진 질문 / 비교한 수	luna: 달라진 질문 / 비교한 수
p1	2/19 (stakes.cost 예→아니오, theme.coherent 아니오→예)	1/19 (longevity.next 예→아니오)
p2	1/18 (versions.separated 예→아니오)	2/18 (consistency.no_conflict 아니오→예, core_rules.stated 예→아니오)
p3	1/21 (protagonist_appeal.root 아니오→예, 주관)	3/21 (arc.change 예→아니오, stakes.cost 아니오→예, exposition.not_dumped 예→아니오)
p4	2/20 (genre_fit.core_fun 아니오→예 주관, cliffhanger.hooks 아니오→예)	2/20 (consistency.no_conflict 아니오→예, cliffhanger.hooks 아니오→예)

합계는 기준선 6건, luna 8건이다. luna의 p2~p4 설정 일관성 변화는 A쪽만 "아니오"라서 생겼다(F7 참고). 1회씩만 돌렸으므로 원인은 가릴 수 없다(F6).

후처리 (runs[].post)

원본 인용 / 원문에 없는 인용 / 후처리로 바뀐 답 순서다.

샘플	기준선	luna
p1a	104 / 0 / 0	87 / 1 / 0
p1b	102 / 0 / 0	85 / 0 / 0
p2a	98 / 0 / 0	80 / 0 / 0
p2b	110 / 0 / 0	87 / 0 / 0
p3a	93 / 0 / 0	62 / 0 / 0
p3b	95 / 0 / 0	67 / 2 / 0
p4a	97 / 0 / 0	72 / 0 / 0
p4b	87 / 0 / 0	66 / 0 / 0
합계	786 / 0 / 0	606 / 3 / 0

원문에 없는 인용은 p1a originality.twist 의 "아델은 식물 이름과 효능을 외우는 게 특기다."와, p3b에서 두 번(설정 일관성 답과 설정 정리의 사건 목록) 나온 "...누구의 제자도 된 적 없다."이다. 뒤의 것은 원문의 "된 적이 없다."에서 한 글자가 빠졌다. 앱은 정확히 일치하지 않는 인용을 버리므로 이 인용은 화면에 나오지 않았다.

F1~F7 판단

사례	기준선	luna
F1 동기 정보 부족을 짐작으로 채움(p2b)	발생("예")	발생하지 않음("아니오", 메모에 설명이 없다고 함). 반대로 p2a에서는 질문 범위를 넓혀 '문제 없음' 라벨과 어긋남
F2 판단과 무관한 인용 통과	p2b에서 발생	구조는 그대로다. p2b는 이번에 "아니오"라 같은 사례는 없음. 예상 근거 밖 인용은 대상 10건 중 5건
F3 먼저 고칠 3가지가 목록 순서로 정해짐	8/8건	8/8건. 빨강이 6~8개로 늘어 영향이 더 큼. p2b 행동 동기와 p4b 결말이 빨강인데도 빠짐
F4 근거 확인 실패가 결함처럼 표시되는 구조	실측 0건, 드라이런으로 확인	실측 0건. 원문에 없는 인용 3개는 다른 인용이 남아 답이 바뀌지 않음
F5 메모에 없는 것과 잘못된 것이 같은 빨강	p4b에서 발생	p2b, p4b 모두 발생
F6 쌍 사이 무관 질문 흔들림	4쌍, 합계 6건	4쌍, 합계 8건
F7 합성 샘플과 임시 라벨의 한계	아래 인용	p4 댐 연도 모순은 p4a에서만 찾음(p4b는 "예"). p2 빛 출처 모순은 설정 일관성에서 두 쪽 모두 지적하지 않음(다른 질문은 확인하지 않음). p2a는 수명 숫자 변화(62년→3일)를 이유로 설정 일관성 "아니오"라고 함. 기준선은 두 결함을 4건 모두에서 찾았다

F7 (기준선 문서에서 그대로 인용):

- p2 메모의 "학자금 빛"과 "아버지 병원비로 생긴 빛", p4 메모의 "2006년 댐"과 "30년 만의 최저 수위"는 샘플을 쓸 때 의도하지 않은 결함이었다. 앱은 해당 4건 모두에서 이를 찾았지만 임시 라벨에는 없었다.
- p3b의 '객잔 이름' 필수 인용은 줄거리 문장 하나만 인정했다. 앱은 반대편 근거로 제목("가제: 흑비단객잔")을 인용해 자동 판정이 '못 찾음'이 되었다.

관문 판정: 실패 (G2, G4)

summary.json 에서 계산했다(스크립트와 출력은 커밋하지 않는 로컬 작업 기록 task-9-gate.txt 의 RERUN 절에 있다).

관문	기준	결과	판정
G1	runs 8건 모두 stage === "done"	8/8	통과
G2	'문제 있음' 3건 모두 finalAnswer no	2/3 (p3b consistency.no_conflict 가 yes)	실패
G3	'문제 없음' 5건 중 yes 4건 이상	4/5 (p2a motivation.reason 가 no)	통과
G4	mustFind 6건 중 found 3건 이상	2/6	실패
G5	mustNotFlag hits 합계 1 이하	0	통과

관문을 넘지 못해 src/components/elapsed-time.tsx 의 TYPICAL_MINUTES 와 README.md 의 비용·소요 시간 문구는 바꾸지 않았다. 참고로 통과했다면 TYPICAL_MINUTES 는 2(중앙값 95초), README 비용은 \$0.006이었다.

사람이 검토해야 할 라벨

기준선 문서의 표와 목록이 그대로 적용된다. 이번에 추가로 볼 것:

샘플	질문	임시 라벨	검토 포인트
p2a	motivation.reason	문제 없음	luna가 두 번 모두 "아니오"라고 답했다. 첫 시도는 조연 미소의 숨긴 목적, 재실행은 서윤이 새벽에 집을 비우는 이유를 들었다. 질문이 주인공의 선택만 묻는지, 주요 인물 전체를 묻는지 정해야 한다. 의도적으로 숨긴 동기를 공백으로 불지도 함께 정한다. 전체로 본다면 라벨은 '문제 있음' 또는 '정보 부족'이 된다
p3b	consistency.no_conflict mustFind	문제 있음	필수 인용이 원문과 한 글자라도 다르면 인정하지 않는다. luna의 인용은 "이"가 빠져 버려졌다. 앱의 정확 일치 규칙이 맞는지, 라벨 판정을 조금 느슨하게 할지 정한다. 모델이 모순을 놓친 것 자체는 인용 규칙과 무관하다

실제 메모로 최종 확인할 때 (이번에는 하지 않음)

기준선 문서의 조건(동의와 보관, 처음 보는 메모, 구성, 라벨 먼저, 반복 실행, 보고 분리)을 그대로 따른다. luna high는 1회에 1.5~2분이 걸려, 메모 5개를 --repeat 3 으로 15회 돌려도 25분 안팎(표준 요금으로 약 \$0.09)이다. 이번 결과처럼 1회 차이를 모델 차이로 읽기 어려운 경우에는 --repeat 3 으로 흔들림을 먼저 재는 것이 싸다.

gpt-6-luna 추론 max 재측정: Claude 기준선·luna high와 비교 (2026-10-01)

gpt-6-luna 를 추론 max 로 올려 합성 기획 메모 8개를 1회씩 다시 진단한 결과다. [BASELINE-2026-09-30.md](#)(Claude Opus, max), [LUNA-2026-09-30.md](#)(luna, high)와 같은 샘플과 라벨로 비교한다. 기준은 [CRITERIA.md](#), 실행 방법은 [README.md](#)에 있다.

이 결과는 합성 메모 8개에 대한 것이다. 실제 사용자 메모에서 검증한 품질이 아니다. 라벨은 AI가 쓴 사람 검토 전 임시 라벨이고, 세 조건 모두 샘플마다 1회씩만 돌렸다. 그래서 아래 차이 중 어디까지가 모델·추론 강도 차이이고 어디부터가 실행마다 생기는 흔들림인지 가릴 수 없다. **luna high와는 출력 스키마도 다르다.** 이번 측정은 답과 항목을 질문별 필수 속성으로 받도록 바꾼 뒤(계획 15번)의 첫 측정이라, high와의 차이에는 추론 강도와 스키마 변경이 섞여 있다.

실행 조건과 건수

- 결과 폴더: `eval/results/20261001-005330/`. 자동 집계는 `summary.md` 와 `summary.json`, 사람 검토표는 `review.csv` (184행)에 있다. 콘솔 기록은 `.omo/evidence/web-diagnosis-openai/task-16-eval.txt`, 관문 계산은 `task-16-gate.txt` 에 있다. 이 두 파일은 커밋하지 않는 로컬 작업 기록이고, 숫자는 커밋된 `summary.json` 으로 다시 계산할 수 있다.
- 표본: 샘플 8개 × 1회로 8건을 계획해 8건을 실행했고, 8건 모두 성공했다(모델 호출 실패 0, 후처리 실패 0, 질문 누락 0). 자동 재시도는 없었다.
- 모델: 설정은 `gpt-6-luna`, 추론 `max` (`OPENAI_EFFORT=max`), 공급자 `openai-responses` 이다. `run-info.json` 의 `settings.effort` 도 `max` 이고, 응답이 보고한 실제 모델도 `gpt-6-luna` 였다.
- 스키마: 계획 15번의 새 출력 스키마(`4e955489cd78221e`)다. luna high는 `761266653eb022df` 였다.
- 버전: `git 881827f` 에 커밋하지 않은 `src/lib/diagnosis/diagnose.ts` (`819e8befc012a42d`), `src/lib/diagnosis/prompt.ts` (`fb1365e361f5bb73`), `src/lib/llm.ts` (`5f62f5e52e0ccd78`) 변경을 더한 상태다. 시스템 프롬프트 해시 `6e63177dca9e3b84`, `rules.ts` `da6a55683be26719`, `items.ts` `1293e659696d7113` 은 기준선·high와 같다.
- 소요 시간: 합계 4,092초(68분), 중앙값 305초, 범위 259~1,218초. 6건은 259~322초였고 p1b(1,124초)와 p2a(1,218초) 두 건이 약 20분씩 걸렸다.
- 비용(표준 요금): 합계 \$0.1581, 1회 평균 \$0.0198, 중앙값 \$0.0198, 최대 \$0.0217. 토큰은 입력 중앙값 7,934, 출력 중앙값 38,389(추론 토큰 포함, 범위 35,230~42,806)이다.

결과 요약 (범주별로 따로 셈, 하나의 정확도로 합치지 않음)

항목	Claude 기준선 (max)	gpt-6-luna (high)	gpt-6-luna (max, 새 스키마)
실행	8건 중 성공 8	8건 중 성공 8	8건 중 성공 8
대상 질문: '문제 없음'	5건 중 "예" 5	5건 중 "예" 4 (p2a motivation. reason 이 "아니오")	5건 중 "예" 4 (p2a motivation. reason 이 또 "아니오")
대상 질문: '문제 있음'	3건 중 "아니오" 3	3건 중 "아니오" 2 (p3b consistency.no_conflict 가 "예")	3건 중 "아니오" 3
대상 질문: '정보 부족'	2건 중 "아니오" 1, "예" 1(p2b)	2건 중 "아니오" 2	2건 중 "아니오" 2

항목	Claude 기준선 (max)	gpt-6-luna (high)	gpt-6-luna (max, 새 스키마)
반드시 찾아야 할 문제(mustFind)	6건 중 찾음 4	6건 중 찾음 2 (p1b, p4b)	6건 중 찾음 2 (p1b, p4b)
하면 안 되는 지적(mustNotFlag)	10건 중 자동 적발 0	10건 중 자동 적발 0	10건 중 자동 적발 2 (p2a miso-hidden, p4b many-culprits)
원문에 없는 인용	786개 중 0	606개 중 3	728개 중 1 (p2a genre_fit.core_fun 의 "현판")
후처리로 바뀐 답	184개 중 0	184개 중 0	184개 중 0
먼저 고칠 3가지	8건 모두 목록 순서. 빨강 3~7개	8건 모두 목록 순서. 빨강 6~8개	8건 모두 목록 순서. 빨강 3~7개
쌍 비교(무관 질문 흔들림)	4쌍, 합계 6건	4쌍, 합계 8건	2쌍, 합계 3건 (p1 0, p2 2, p3 0, p4 1)
소요 시간	합계 6,485초, 중앙값 737초, 614~1,050초	합계 798초, 중앙값 95초, 90~120초	합계 4,092초, 중앙값 305초, 259~1,218초
비용(표준 요금)	기록 없음(구독 CLI)	합계 \$0.0484, 평균 \$0.0060, 최대 \$0.0068	합계 \$0.1581, 평균 \$0.0198, 최대 \$0.0217
출력 토큰 중앙값	기록 없음	11,791	38,389

max로 올리자 high에서 놓친 p3b 설정 일관성이 "아니오"로 돌아왔고, 쌍 사이 흔들림과 원문에 없는 인용, 빨강 개수가 줄었다. 반면 mustFind는 2/6 그대로이고, 하면 안 되는 지적이 0에서 2로 늘었다. 비용은 약 3.3배, 소요 시간 중앙값은 약 3.2배이며 두 건은 20분 안팎이 걸렸다. Claude 기준선보다는 여전히 중앙값 기준 약 2.4배 빠르다.

요청한 네 가지 분석

- 근거 확인 실패로 바뀐 "예→아니오"가 작품의 결함으로 표시되는가: 이번에도 0건이다. 원문에 없는 인용 1개(p2a)가 버려졌지만 그 답은 바뀌지 않았다.
- 메모에 없는 내용과 실제로 잘못된 내용을 구분하는가: '정보 부족' 라벨 2건(p2b, p4b)은 모두 "아니오"였고 이유에 "적혀 있지 않아요", "메모에 없어요"를 썼다. 신호는 두 건 모두 빨강 fix 다.
- 먼저 고칠 3가지가 목록 순서의 영향을 받는가: 8건 모두 빨강을 목록 순서대로 잘랐다(followsTableOrder 8/8). 빨강은 3~7개였고, 7건에서 1~4개가 순서 때문에 빠졌다. p4b의 결말(17번째)은 빨강인데 빠졌고, p2b의 행동 동기는 이번에는 포함됐다. 장르 재미는 5/8건에서 한 자리를 차지했다(기준선 7/8, high 4/8).
- 원문에 있지만 판단과 무관한 인용도 통과하는가: 대상 질문 10건 중 예상 근거 밖 인용이 있는 것은 8건이다(p1a 3개, p1b 1개, p2a 3개, p2b 2개, p3a 설정 일관성 3개, p3b 설정 일관성 2개, p4a 1개, p4b 1개). 기준선은 9건, high는 5건이었다. 관련성은 review.csv 에서 사람이 확인한다.

F1~F7 비교

max 값은 eval/results/20261001-005330/summary.json , high 값은 eval/results/20260930-085033/summary.json , 기준선 값은 eval/results/20260930-011259/summary.json 의 같은 필드에서 읽었다.

대상 질문 (targets)

finalAnswer / 먼저 고칠 3(inTopFixes) / 근거 없음으로 바뀜(downgradedForEvidence) 순서다.

샘플	질문	임시 라벨	기준선	luna high	luna max
p1a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오

샘플	질문	임시 라벨	기준선	luna high	luna max
p1b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오
p2a	motivation.reason	문제 없음	yes / - / 아니오	no / - / 아니오	no / 포함 / 아니오
p2b	motivation.reason	정보 부족	yes / - / 아니오	no / - / 아니오	no / 포함 / 아니오
p3a	versions.separated	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오
p3a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오
p3b	versions.separated	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오
p3b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	yes / - / 아니오	no / 포함 / 아니오
p4a	ending.decided	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오
p4b	ending.decided	정보 부족	no / - / 아니오	no / - / 아니오	no / - / 아니오

- **p3b 설정 일관성 "아니오"**: 이유는 "설정 메모에서는 객잔 이름을 청운객잔으로 정했지만, 작품 가제와 마 노인 소개에서는 흑비단객잔을 객잔명처럼 사용해요"였다. 심어 둔 다른 모순(첩자로 길러짐과 '누구의 제자도 된 적 없음')은 이유에도 인용에도 없다.
- **p3b 버전 정리 "아니오"(인용 0개)**: "수정 전·폐기안·최종 채택안을 구분한 표기나 설명이 없어요"라고 했지만 근거 인용을 하나도 달지 않았다.
- **p2a 행동 동기 "아니오"(세 번째 불일치)**: 아래 [라벨 범위 질문](#) 참고.
- **p4b 결말 "아니오"**: 빨강이지만 목록 17번째라 먼저 고칠 3가지에서 또 빠졌다(F3, 세 조건 모두 같음).

반드시 찾아야 할 문제 (mustFind)

샘플	문제	기준선	luna high (답, 필수 인용)	luna max (답, 필수 인용)
p1b	죽은 테오의 학비를 마련하려 함	찾음	찾음 (아니오, 2/2)	찾음 (아니오, 2/2)
p2b	세 선택의 이유가 없음	못 찾음	못 찾음 (아니오, 2/3)	못 찾음 (아니오, 1/3)
p3b	첩자 설정과 '누구의 제자도 된 적 없음'	찾음	못 찾음 (예, 1/2)	못 찾음 (아니오, 0/2)
p3b	객잔 이름이 엇갈림	못 찾음(F7 라벨 한계)	못 찾음 (예, 0/2)	못 찾음 (아니오, 1/2)
p3b	최종·폐기 표시 없음	찾음	못 찾음 (아니오, 0/2)	못 찾음 (아니오, 0/2)
p4b	결말이 없음	찾음	찾음 (아니오)	찾음 (아니오)

max에서 '못 찾음' 4건은 답이 모두 "아니오"이고, 필수 인용 수가 기준에 못 미쳐 found 가 false다.

- p2b 세 선택(1/3): 필수 인용 3개 중 "한결은 서윤을 구하기로 한다." 하나만 인용했다.
- p3b 첩자 설정(0/2): 설정 일관성 답의 이유와 인용에 이 내용이 없다.
- p3b 객잔 이름(1/2): "객잔 이름은 '청운객잔'이다."를 인용했고, 반대편으로는 "가제: 흑비단객잔"과 마 노인 소개 문장을 인용했다. 라벨의 필수 인용은 "소운이 흑비단객잔에 점소리로 들어온다."이다.
- p3b 버전 표시 없음(0/2): 버전 정리 답에 인용이 0개다.

하면 안 되는 지적 (mustNotFlag)

10건 중 자동 적발 2건이다(기준선 0, high 0).

- **p2a miso-hidden**: motivation.reason "아니오"의 근거로 "미소의 정체와 목적은 2부 중반에 공개한다.", "1부에서는 일부러 숨긴다."를 인용했다. G3의 p2a 불일치와 같은 답이다.

- **p4b many-culprits**: `turning_points.why` "아니오"의 근거로 "은주의 실종에는 마을 사람 여럿이 조금씩 관여했다. 한 사람의 범행이 아니다."를 인용했다. 이유는 "그 단서들이 어떤 증거를 거쳐 결론으로 이어지는지는 적혀 있지 않아요... 주요 반전의 인과가 아직 부족해요"였다. 자동 판정은 라벨의 금지 문장이 해당 질문의 "아니오" 근거로 인용됐는지를 센다.
- 사람만 판단할 수 있는 p4b `invented-ending` 은 자동 적발 대상이 아니다 (`humanOnly`). `ending.decided` 의 이유는 "그 뒤 은서가 어떤 행동을 하고 책임 문제가 어떻게 마무리되는지는 메모에 없어요"였다.

쌍 비교 (pairs)

쌍	기준선	luna high	luna max
p1	2/19	1/19	0/19
p2	1/18	2/18	2/18 (<code>turning_points.why</code> 예→아니오, <code>cliffhanger.hooks</code> 예→아니오)
p3	1/21	3/21	0/21
p4	2/20	2/20	1/20 (<code>consistency.no_conflict</code> 아니오→예)
합계	6	8	3

p4의 변화는 댐 연도 결함(F7)을 p4a에서만 찾고 p4b에서는 "예"라고 한 것이다. high도 같았다. p2의 설정 일관성은 A·B 모두 "아니오"였는데, 이유는 빗 출처가 아니라 수명 숫자(62년→3일)가 규칙과 어긋나 보인다는 것이다.

후처리, 소요 시간, 비용, 토큰 (`runs[].post` , `runs[].meta`)

원본 인용 / 원문에 없는 인용 / 후처리로 바뀐 답 순서다.

샘플	기준선	luna high	luna max	max 소요(초)	max 출력 토큰(그중 추론)	max 비용
p1a	104 / 0 / 0	87 / 1 / 0	78 / 0 / 0	271	37,319 (28,500)	\$0.0197
p1b	102 / 0 / 0	85 / 0 / 0	98 / 0 / 0	1,124	37,304 (28,231)	\$0.0189
p2a	98 / 0 / 0	80 / 0 / 0	100 / 1 / 0	1,218	36,258 (27,452)	\$0.0184
p2b	110 / 0 / 0	87 / 0 / 0	98 / 0 / 0	322	42,806 (33,903)	\$0.0217
p3a	93 / 0 / 0	62 / 0 / 0	88 / 0 / 0	294	40,417 (31,915)	\$0.0205
p3b	95 / 0 / 0	67 / 2 / 0	76 / 0 / 0	259	35,230 (26,487)	\$0.0179
p4a	97 / 0 / 0	72 / 0 / 0	110 / 0 / 0	288	39,459 (31,181)	\$0.0200
p4b	87 / 0 / 0	66 / 0 / 0	80 / 0 / 0	316	41,580 (33,839)	\$0.0210
합계	786 / 0 / 0	606 / 3 / 0	728 / 1 / 0	4,092 (중앙값 305)	중앙값 38,389	\$0.1581 (중앙값 \$0.0198, 최대 \$0.0217)

원문에 없는 인용 1개는 p2a `genre_fit.core_fun` 의 "현판"이다. 애플이 버렸고 답은 바뀌지 않았다. 질문 누락은 8건 모두 0으로, 새 스키마가 의도한 대로 동작했다. 두 건(p1b 1,124초, p2a 1,218초)은 약 19~20분이 걸렸는데, 출력 토큰(37,304와 36,258)은 4.3~5.4분 걸린 나머지 6건(35,230~42,806)과 같은 수준이다. 시간이 길어진 원인은 기록에 없다.

F1~F7 판단

사례	기준선	luna high	luna max
F1 동기 정보 부족을 짐작으로 채움(p2b)	발생("예")	발생하지 않음("아니오")	발생하지 않음("아니오"). p2a는 "아니오"로 '문제 없음' 라벨과 불일치
F2 판단과 무관한 인용 통과	p2b에서 발생	예상 근거 밖 인용이 대상 10건 중 5건	예상 근거 밖 인용이 대상 10건 중 8건

사례	기준선	luna high	luna max
F3 먼저 고칠 3가지가 목록 순서로 정해짐	8/8건	8/8건, 빨강 6~8개	8/8건, 빨강 3~7개. p4b 결말이 빨강인데 빠짐
F4 근거 확인 실패가 결함처럼 표시되는 구조	실측 0건	실측 0건	실측 0건
F5 메모에 없는 것과 잘못된 것이 같은 빨강	p4b에서 발생	p2b, p4b	p2b, p4b
F6 쌍 사이 무관 질문 흔들림	4쌍, 합계 6건	4쌍, 합계 8건	2쌍, 합계 3건
F7 합성 샘플과 임시 라벨의 한계	아래 인용	p4 댐 연도는 p4a에서만 지적	p4 댐 연도는 p4a에서만 지적(p4b는 "예"). p2a-p2b 설정 일관성은 "아니오"이고 이유는 수명 숫자(62년→3일)다

F7 (기준선 문서에서 그대로 인용):

- p2 메모의 "학자금 빚"과 "아버지 병원비로 생긴 빚", p4 메모의 "2006년 댐"과 "30년 만의 최저 수위"는 샘플을 쓸 때 의도하지 않은 결함이었다. 애플은 해당 4건 모두에서 이를 찾았지만 임시 라벨에는 없었다.
- p3b의 '객잔 이름' 필수 인용은 줄거리 문장 하나만 인정했다. 애플은 반대편 근거로 제목("가제: 흑비단객잔")을 인용해 자동 판정이 '못 찾음'이 되었다.

관문 판정: 실패 (G4, G5)

summary.json 에서 계산했다(스크립트와 출력은 커밋하지 않는 로컬 작업 기록 task-16-gate.txt 에 있다).

관문	기준	luna high	luna max	판정(max)
G1	runs 8건 모두 stage === "done"	8/8	8/8	통과
G2	'문제 있음' 3건 모두 finalAnswer no	2/3	3/3	통과
G3	'문제 없음' 5건 중 yes 4건 이상	4/5	4/5 (p2a motivation.reason 가 no)	통과
G4	mustFind 6건 중 found 3건 이상	2/6	2/6	실패
G5	mustNotFlag hits 합계 1 이하	0	2	실패

high는 G2와 G4에서, max는 G4와 G5에서 실패했다. max로 올려 G2는 넘었지만 G5를 새로 놓쳤다.

관문은 G4와 G5에서 실패했다. 작성자가 2026-10-01에 이 결과를 확인하고, 그래도 추론 max 로 배포하기로 결정했다. 그래서 이 측정 뒤에 다음을 바꿨다: 기본 추론 강도를 max 로(src/lib/llm.ts), 기본값 표기를 max 로(.env.example, eval/README.md), src/components/elapsed-time.tsx 의 TYPICAL_MINUTES 를 6으로(중앙값 305초), README.md 에 비용·소요 시간 문구를 추가(1회 약 \$0.020, 보통 6분, 8건 중 2건은 약 20분).

관문 기준과 라벨은 바꾸지 않았다. G4의 '못 찾음' 4건과 G5의 적발 2건의 내용은 위 mustFind·mustNotFlag 절에 있다. G5의 p2a 적발과 G3의 p2a 불일치는 같은 답(motivation.reason)에서 나왔다.

사람이 검토해야 할 라벨

기준선 문서와 LUNA-2026-09-30.md의 표와 목록이 그대로 적용된다. 이번에 추가로 볼 것은 아래 한 가지다.

p2a motivation.reason 라벨 범위 질문

임시 라벨은 '문제 없음'인데 luna는 세 번(첫 시도, high 재실행, 이번 max) 모두 "아니오"라고 답했다. 이번 이유는 다음과 같다.

한결이 서운을 구하고 회수인과 맞서는 이유는 적혀 있지만, 서운이 새벽마다 집을 비우는 이유와 미소가 1부에서 개입하는 구체적인 목적은 메모에 드러나지 않아요. 미스터리로 감추려는 계획은 보이지만, 주요 인물의 선택을 움직이는 이유까지는 아직 확인할 수 없어요.

모델은 주인공 한결의 동기는 적혀 있다고 인정하면서, 서운과 미소의 숨긴 이유를 들어 "아니오"라고 했다. 라벨이 예상한 근거(한결의 세 선택 이유 문장)는 3개 중 하나도 인용하지 않았다. 사람이 정해야 할 것은 두 가지다.

1. **질문의 범위:** "중요한 선택마다 이유가 적혀 있는가?"가 주인공의 선택만 묻는가, 주요 인물 전체를 묻는가. 주인공만이라면 p2a는 '문제 없음'이 맞고 luna의 답은 범위를 넓혀 읽은 오류다. 전체라면 라벨이 '문제 있음' 또는 '정보 부족'으로 바뀐다.
2. **의도적으로 숨긴 동기:** 작가가 "일부러 숨긴다"고 적은 동기를 공백으로 볼 것인가. 공백으로 보지 않는다면 p2a의 `miso-hidden` 금지 항목이 그대로 유효하고, 프롬프트에 "작가가 숨긴다고 밝힌 정보는 누락으로 세지 않는다"는 규칙이 필요하다.

이 두 가지는 사람이 정한다. 이 문서는 라벨도 프롬프트도 바꾸지 않았다.

실제 메모로 최종 확인할 때 (이번에는 하지 않음)

기준선 문서의 조건(동의와 보관, 처음 보는 메모, 구성, 라벨 먼저, 반복 실행, 보고 분리)을 그대로 따른다. luna max는 1회에 보통 5분 안팎이지만 이번 8건 중 2건은 약 20분이 걸렸다. 메모 5개를 `--repeat 3` 으로 15회 돌리면 표준 요금으로 약 \$0.30이고, 시간은 1시간 15분에서 길게는 2시간 넘게 잡아야 한다.

gpt-6-luna 추론 max 반복 측정: 같은 메모를 3회씩 (2026-10-02)

같은 합성 기획 메모 8개를 gpt-6-luna, 추론 max 로 3회씩 진단해서, 같은 입력에서 판정이 얼마나 유지되는지 켄 결과다. 앞선 세 측정(BASELINE-2026-09-30.md, LUNA-2026-09-30.md, LUNA-2026-10-01.md)은 모두 샘플마다 1회씩이라 반복 일관성을 재지 못했다. 기준은 CRITERIA.md, 실행 방법은 README.md에 있다.

이 결과는 합성 메모 8개에 대한 것이다. 실제 사용자 메모에서 검증한 품질이 아니다. 라벨은 AI가 쓴 사람 검토 전 임시 라벨이다. 이번 측정은 같은 입력에 같은 답을 내는지를 본 것이고, 바뀐 답 가운데 어느 쪽이 맞는지는 판정하지 않았다.

실행 조건과 건수

- **결과 폴더:** eval/results/20261002-050136/. 자동 집계는 summary.md 와 summary.json, 사람 검토표는 review.csv (552행)에 있다.
- **표본:** 샘플 8개 × 3회로 24건을 계획해 24건을 실행했고, 24건 모두 성공했다(모델 호출 실패 0, 후처리 실패 0, 질문 누락 0). 자동 재시도는 없었고 유료 호출은 24회다.
- **실행 순서:** 샘플마다 3회를 연달아 돌렸다(p1a 1·2·3회차, 다음에 p1b 1·2·3회차 순). 그래서 "회차"는 같은 샘플 안의 순번이고, 같은 회차끼리 같은 시간대에 돈 것이 아니다.
- **모델:** 설정은 gpt-6-luna, 추론 max (기본값), 공급자 openai-responses 이다. 응답이 보고한 실제 모델도 gpt-6-luna 였다.
- **버전:** git a664ce8, 커밋하지 않은 버전 파일 없음. 시스템 프롬프트 6e63177dca9e3b84, 출력 스키마 4e955489cd78221e, prompt.ts fb1365e361f5bb73, rules.ts da6a55683be26719, items.ts 1293e659696d7113 은 2026-10-01 측정과 같다. diagnose.ts(e051e644b7175018)와 llm.ts(c5a3f9347b7d6023)는 그 뒤에 바뀌었다(기본 추론 강도 max, 계정별 메타데이터). 판정 프롬프트, 스키마, 규칙이 같으므로 2026-10-01의 1회 결과를 네 번째 반복으로 함께 볼 수 있다.
- **샘플과 라벨:** 바꾸지 않았다. F7(p2의 빛 출처, p4의 댐 연도)도 고치지 않았다. 작성자가 2026-10-02에, 기존 결과와 직접 비교할 수 있도록 그대로 돌리기로 정했다.
- **소요 시간:** 합계 7,405초(2시간 3분), 중앙값 266초, 범위 207~1,219초. 23건은 207~373초였고 p3b 1회차 한 건이 1,219초 걸렸다.
- **비용(표준 요금):** 합계 \$0.4584, 1회 평균 \$0.0191, 중앙값 \$0.0190, 최대 \$0.0260. 토큰은 입력 중앙값 7,934, 출력 중앙값 37,597.5(추론 토큰 포함, 범위 28,944~51,423)이다.
- **콘솔 기록과 분석 스크립트는 커밋하지 않는 로컬 작업 기록 .omo/evidence/perf-repeat/ 에 있다.** 이 문서의 표는 그 스크립트가 커밋된 summary.json 과 report.json 에서 뽑은 것이라, 같은 파일로 다시 계산할 수 있다.

결과 요약 (범주별로 따로 셈, 하나의 정확도로 합치지 않음)

- **같은 메모를 3회 진단하면 23개 질문 중 2~5개의 답이 달라졌다.** 8개 샘플 × 23개 질문 = 184칸 중 22칸(주관 문항 1칸 포함)에서 답이 갈렸고, 한 번도 갈리지 않은 샘플은 없다.
- **흔들림은 일부 질문에 몰려 있다.** 23개 질문 중 14개는 어느 샘플에서도 갈리지 않았다. 나머지 9개 가운데 회차 끝 긴장과 설명 분산이 각 4개 샘플에서, 설정 일관성·버전 정리·갈등의 크기가 각 3개 샘플에서 갈렸다.
- **대상 질문 10건 중 9건은 3회 모두 같은 답이었다.** 바뀐 1건은 p3a 설정 일관성(예/예/아니오)이다. 심어 둔 '문제 있음' 3건과 '정보 부족' 2건은 3회 모두 "아니오"였다.
- **먼저 고칠 3가지가 3회 모두 같았던 샘플은 8개 중 2개다(p1a, p3b).**

- 관문은 어느 회차도 다섯 개를 모두 통과하지 못했다. 1·2회차는 G5, 3회차는 G3에서 실패했다. 회차에 따라 실패하는 관문이 달랐다.
- 소요 시간 중앙값은 266초, 비용은 1회 평균 \$0.0191이다. 24건 중 1건이 약 20분 걸렸다.

항목	2026-10-01 (max, 1회)	1회차	2회차	3회차
실행	8건 중 성공 8	8건 중 성공 8	8건 중 성공 8	8건 중 성공 8
대상 질문: '문제 없음' 5건 중 "예"	4	4	4	3
대상 질문: '문제 있음' 3건 중 "아니오"	3	3	3	3
대상 질문: '정보 부족' 2건 중 "아니오"	2	2	2	2
반드시 찾아야 할 문제 6건 중 찾을	2	3	4	3
하면 안 되는 지적 10건 중 자동 적발	2	3	3	1
원문에 없는 인용	728개 중 1	690개 중 2	710개 중 1	750개 중 1
후처리로 바뀐 답	0	0	0	0
쌍 비교(무관 질문 차이)	3건	9건	5건	5건
소요 시간 중앙값	305초	265초	257초	286초
비용 합계(8건)	\$0.1581	\$0.1571	\$0.1436	\$0.1577

요청한 네 가지 분석

앞선 세 문서가 본 네 가지를 이번 24건으로 다시 봤다.

1. 근거 확인 실패로 바뀐 "예→아니오"가 작품의 결함으로 표시되는가: 이번에도 0건이다. 원문에 없는 인용 4개를 애플이 버렸지만, 그 인용이 달린 답과 항목에는 다른 인용이 남아 있어 답이 바뀌지 않았다. 구조는 기준선 문서 F4와 같다.
2. 메모에 없는 내용과 실제로 잘못된 내용을 구분하는가: 신호로는 구분하지 못한다. '정보 부족' 2건(p2b, p4b)은 6회 모두 "아니오"였고 6회 모두 빨강 "고쳐보세요"였다(F5). 이유나 코멘트에 '메모에 없다' 류의 표현이 있는 것은 휴리스틱 기준으로 6회 중 5회다.
3. 먼저 고칠 3가지가 목록 순서의 영향을 받는가: 그렇다. 24건 모두 빨강을 목록 순서대로 잘랐다(followsTableOrder 24/24). 빨강이 4~9개여서 24건 모두에서 1~6개가 순서 때문에 빠졌다. p4b의 결말 방향(17번째)은 3회 모두 빨강인데 3회 모두 빠졌다. 주관 문항인 장르 재미는 14/24건에서 한 자리를 차지했다(2026-10-01은 5/8).
4. 원문에 있지만 판단과 무관한 인용도 통과하는가: 구조는 그대로다(F2). 대상 질문 10건 중 예상 근거 밖 인용이 있는 것은 회차별로 6건, 9건, 6건이다(2026-10-01은 8건). 관련성은 review.csv 에서 사람이 확인한다.

반복 일관성

샘플별로 바뀐 질문

샘플	성공 회차	바뀐 질문 수 (23개 중)	바뀐 대상 질문	바뀐 질문과 답 (1회차/2회차/3회차)
p1a	3/3	2	없음	cliffhanger.hooks (회차 끝 긴장) 아니오/예/예, exposition.not_dumped (설명 분산) 아니오/아니오/예
p1b	3/3	2	없음	versions.separated (버전 정리) 예/아니오/아니오, exposition.not_dumped (설명 분산) 아니오/아니오/예
p2a	3/3	3	없음	core_rules.stated (핵심 규칙) 아니오/예/예, turning_points.why (전환점 이유) 예/아니오/아니오, cliffhanger.hooks (회차 끝 긴장) 아니오/예/아니오

샘플	성공 회차	바뀐 질문 수 (23개 중)	바뀐 대상 질문	바뀐 질문과 답 (1회차/2회차/3회차)
p2b	3/3	5	없음	consistency.no_conflict (설정 일관성) 예/예/아니오, core_rules.stated (핵심 규칙) 아니오/예/예, versions.separated (버전 정리) 아니오/예/예, genre_fit.core_fun (장르 재미) 주관 예/아니오/아니오, cliffhanger.hooks (회차 끝 긴장) 예/아니오/예
p3a	3/3	2	consistency.no_conflict	consistency.no_conflict (설정 일관성) 예/예/아니오, exposition.not_dumped (설명 분산) 아니오/예/아니오
p3b	3/3	3	없음	stakes.cost (갈등의 크기) 예/아니오/아니오, cliffhanger.hooks (회차 끝 긴장) 예/예/아니오, exposition.not_dumped (설명 분산) 예/아니오/아니오
p4a	3/3	3	없음	consistency.no_conflict (설정 일관성) 아니오/예/예, versions.separated (버전 정리) 예/아니오/아니오, stakes.cost (갈등의 크기) 예/아니오/예
p4b	3/3	2	없음	longevity.next (연재 지속성) 아니오/예/아니오, stakes.cost (갈등의 크기) 예/예/아니오

합계: 샘플 8개 × 질문 23개 = 184칸 중 22칸에서 답이 바뀌었다(주관 문항 1칸 포함). 한 번도 바뀌지 않은 샘플은 0개다.

질문	바뀐 샘플 수	샘플
cliffhanger.hooks (회차 끝 긴장)	4	p1a, p2a, p2b, p3b
exposition.not_dumped (설명 분산)	4	p1a, p1b, p3a, p3b
versions.separated (버전 정리)	3	p1b, p2b, p4a
consistency.no_conflict (설정 일관성)	3	p2b, p3a, p4a
stakes.cost (갈등의 크기)	3	p3b, p4a, p4b
core_rules.stated (핵심 규칙)	2	p2a, p2b
turning_points.why (전환점 이유)	1	p2a
genre_fit.core_fun (장르 재미) 주관	1	p2b
longevity.next (연재 지속성)	1	p4b

질문별 분포

축	질문	p1a	p1b	p2a	p2b	p3a	p3b	p4a	p4b	갈린 샘플 수
설정	consistency.no_conflict (설정 일관성)	3/3	0/3	3/3	2/3	2/3	0/3	2/3	3/3	3
설정	core_rules.stated (핵심 규칙)	3/3	3/3	2/3	2/3	3/3	3/3	3/3	3/3	2
설정	versions.separated (버전 정리)	0/3	1/3	0/3	2/3	3/3	0/3	1/3	0/3	3
상업성	logline_hook.parts (로그라인 훅)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
상업성	longevity.next (연재 지속성)	3/3	3/3	3/3	3/3	0/3	0/3	0/3	1/3	1
상업성	genre_fit.core_fun (장르 재미) 주관	0/3	0/3	0/3	1/3	0/3	0/3	3/3	3/3	1
상업성	originality.twist (개성) 주관	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
상업성	selling_point.clear (셀링 포인트) 주관	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
캐릭터	desire_lack.want (욕망과 결핍)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
캐릭터	desire_lack.lack (욕망과 결핍)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
캐릭터	motivation.reason (행동 동기)	0/3	0/3	0/3	0/3	0/3	0/3	0/3	0/3	0
캐릭터	supporting.role (조연 역할)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
캐릭터	protagonist_appeal.root (주인공 매력) 주관	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0

축	질문	p1a	p1b	p2a	p2b	p3a	p3b	p4a	p4b	갈린 샘플 수
캐릭터	arc.change (인물 변화)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0/3	0
서사	central_question.exists (중심 질문)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
서사	stakes.cost (갈등의 크기)	3/3	3/3	3/3	3/3	0/3	1/3	2/3	2/3	3
서사	turning_points.why (전환점 이유)	0/3	0/3	1/3	0/3	0/3	0/3	0/3	0/3	1
서사	ending.decided (결말 방향)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0/3	0
서사	theme.coherent (주제 일관성)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0/3	0
웹툰 연재	first_episode.event (첫 화 사건)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
웹툰 연재	early_pace.goal_early (초반 전개)	3/3	3/3	3/3	3/3	3/3	3/3	3/3	3/3	0
웹툰 연재	cliffhanger.hooks (회차 끝 긴장)	2/3	3/3	1/3	2/3	3/3	2/3	3/3	3/3	4
웹툰 연재	exposition.not_dumped (설명 분산)	1/3	1/3	3/3	3/3	1/3	1/3	3/3	3/3	4

칸의 값은 끝난 실행 중 "예"라고 답한 횟수다. 굵은 칸은 같은 메모에서 답이 갈린 경우다. 갈린 칸 22/184. 집계한 리포트 24건 (샘플별 p1a 3, p1b 3, p2a 3, p2b 3, p3a 3, p3b 3, p4a 3, p4b 3).

바뀐 답의 내용

같은 메모에서 답이 갈린 경우를 샘플별로 적는다. 답이 갈린 22칸 중 18칸에서는 "예"라고 한 실행과 "아니오"라고 한 실행이 같은 문장을 하나 이상 인용했다. 같은 근거를 두고, 적혀 있는 것으로 충분한지를 다르게 본 것이다. 나머지 4칸 중 3칸은 버전 정리이고 "아니오"라고 한 실행에 인용이 없다.

p1a (로판, 설정이 일관됨)

- cliffhanger.hooks (회차 끝 긴장) 아니오/예/예. 세 번 모두 1화의 화분 이동과 3화의 황태자 잔을 근거로 들었다. 1회차만 중반-후반 사건이 큰 줄거리로만 적혀 있어 "긴 연재 내내 절단 지점이 이어질지는 확인할 수 없어요"라며 "아니오"라고 했다.
- exposition.not_dumped (설명 분산) 아니오/아니오/예. 1·2회차는 규칙을 어느 장면에서 알릴지 적혀 있지 않아 확인할 수 없다고 했고, 3회차는 설정의 활용이 여러 구간에 나뉘었다고 했다.

p1b (로판, 죽은 남동생의 학비라는 충돌을 심음)

- 심은 충돌은 3회 모두 찾았다. 총평 세 개가 모두 이 충돌을 짚었고 설정 일관성이 3회 모두 먼저 고칠 3가지의 첫 자리였다.
- versions.separated (버전 정리) 예/아니오/아니오. 이 메모에는 버리거나 바꾼 설정이 없다. 1회차는 서로 다른 판본이 섞였다고 볼 근거가 없다고 했고(예), 2·3회차는 변경·폐기 표시가 없어 최종안이 구분되는지 확인할 수 없다고 했다(아니오, 인용 0개).
- exposition.not_dumped (설명 분산) 아니오/아니오/예. p1a와 같은 갈림이다.

p2a (현판, 세 선택마다 동기 문장이 있음)

- 대상 질문인 행동 동기는 3회 모두 "아니오"였지만 이유가 달랐다. 1·2회차는 조연(서윤, 미소)의 숨긴 동기가 메모에 없다는 것이었고, 3회차는 결말에서 한결이 거래 장부를 불태우는 선택의 목적이 적혀 있지 않다는 것이었다.
- core_rules.stated (핵심 규칙) 아니오/예/예와 turning_points.why (전환점 이유) 예/아니오/아니오. 수명 계약이 어떻게 작동하는지(구한 뒤 62년이던 숫자가 3일로 돌아오는 조건, 10년을 내면 계약이 깨지는 방식)가 적혀 있지 않다는 공백을 1회차는 핵심 규칙에서, 2·3회차는 전환점 이유에서 지적했다. 2·3회차는 결말의 장부 소각이 어떤 효과를 내는지도 없다는 점을 더했다. 지적 내용은 겹치고 귀속된 항목이 달라졌다.
- cliffhanger.hooks (회차 끝 긴장) 아니오/예/아니오. 세 번 모두 1화의 3일과 3화의 미소 대사를 근거로 들었고, 4화 이후가 요약뿐이라는 점을 "아니오"의 이유로 삼느냐가 갈렸다.

p2b (현판, 동기 문장 세 개를 지움)

- 지운 동기는 3회 모두 "아니오"였고, 행동 동기가 3회 모두 먼저 고칠 3가지에 들어갔다.
- 바뀐 질문이 5개로 가장 많다. `consistency.no_conflict` (설정 일관성) 예/예/아니오, `core_rules.stated` (핵심 규칙) 아니오/예/예, `versions.separated` (버전 정리) 아니오/예/예, `genre_fit.core_fun` (장르 재미, 주관) 예/아니오/아니오, `cliffhanger.hooks` (회차 끝 긴장) 예/아니오/예.
- p2a와 같은 공백(계약이 수명을 되돌리는 원리)이 1회차는 핵심 규칙, 3회차는 설정 일관성에 붙었다. 3회차는 이것을 "서로 충돌하는지 독자가 판단하기 어려워요"라며 어긋나는 설정으로 읽었고, 1·2회차는 모순이 아니라 계약에서 나오는 갈등으로 읽었다.

p3a (무협, 폐기안과 최종안이 표시로 구분됨)

- 대상 질문 `consistency.no_conflict` (설정 일관성, 라벨 '문제 없음')가 예/예/아니오로 바뀌었다. 3회차는 2화에서 장부가 객잔 지하에 있다고 알아내는데 3화에서는 그 지하에서 장부 대신 거래 문서를 발견한다는 점을 어긋나는 설정으로 봤다. [폐기] 표시한 설정을 문제 삼은 것은 아니어서 금지 항목에는 걸리지 않는다. 줄거리 전개를 모순으로 읽은 것으로 보이며, 오탐인지는 사람이 확인한다.
- `exposition.not_dumped` (설명 분산) 아니오/예/아니오. p1a, p1b와 같은 갈림이다.

p3b (무협, 폐기안과 최종안을 구분 없이 섞어 씀)

- 대상 질문 둘(`consistency.no_conflict`, `versions.separated`)은 3회 모두 "아니오"로 같았고, 먼저 고칠 3가지도 3회 모두 [설정 일관성, 버전 정리, 연재 지속성]이었다.
- 다만 설정 일관성의 이유는 3회 모두 객잔 이름(청운객잔과 흑비단객잔)뿐이다. 심어 둔 다른 모순(첩자로 길러졌다는 설정과 누구의 제자도 된 적 없다는 설정)은 3회 모두 짚지 않았다. 첩자 문장은 3회 모두 주인공 매력("예")의 근거로 인용했고 2회차는 두 문장을 설명 분산의 근거로 나란히 인용했지만, 서로 어긋난다고 본 실행은 없다.
- `stakes.cost` (갈등의 크기) 예/아니오/아니오, `cliffhanger.hooks` (회차 끝 긴장) 예/예/아니오, `exposition.not_dumped` (설명 분산) 예/아니오/아니오. 세 질문 모두 적혀 있는 것으로 충분한지를 두고 갈렸다.

p4a (스릴러, 결말이 적혀 있음)

- `consistency.no_conflict` (설정 일관성) 아니오/예/예. 1회차만 2006년에 댐이 생겼는데 수위가 30년 만에 최저라는 연표 문제를 짚었다. 이것은 샘플을 쓸 때 의도하지 않은 결함(F7)이다. 2·3회차는 어긋나는 설정이 없다고 했고, 3회차는 그 두 문장을 "예"의 근거로 인용했다.
- `versions.separated` (버전 정리) 예/아니오/아니오. 버린 설정이 없는 메모에서 나오는 같은 갈림이다(p1b, p2b와 같음).
- `stakes.cost` (갈등의 크기) 예/아니오/예. 세 번 모두 같은 세 문장을 인용했고, 실패했을 때 잃을 것이 구체적인지를 두고 갈렸다.

p4b (스릴러, 결말 줄을 지움)

- 지운 결말은 3회 모두 "아니오"였고, 이유는 세 번 다 결말이 메모에 적혀 있지 않다는 것이었다. 방향도 세 번 다 결말의 지점을 정해 보라는 제안이었다.
- `longevity.next` (연재 지속성) 아니오/예/아니오와 `stakes.cost` (갈등의 크기) 예/예/아니오. 근거 문장은 겹친다. 공동 책임이라는 질문이 남는 것을 다음 갈등으로 인정하느냐, 수위 상승을 실패의 대가로 인정하느냐가 갈렸다.
- 설정 일관성은 3회 모두 "예"였고, 3회 모두 댐 연도 문장(2006년 댐 건설, 30년 만의 최저 수위)을 그 근거로 인용했다(F7).

먼저 고칠 3가지

괄호는 22개 항목 목록에서의 순번이다. '빠진 빨강'은 빨강인데 3가지에 들지 못한 항목이다.

샘플	1회차	2회차	3회차	3회 모두 같은가	빨강 개수	빠진 빨강
p1a	버전 정리(3), 장르 재미(6), 행동 동기(10)	버전 정리(3), 장르 재미(6), 행동 동기(10)	버전 정리(3), 장르 재미(6), 행동 동기(10)	예	6/5/4	전환점 이유·회차 끝 긴장·설명 분산 / 전환점 이유·설명 분산 / 전환점 이유
p1b	설정 일관성(1), 장르 재미(6), 행동 동기(10)	설정 일관성(1), 버전 정리(3), 장르 재미(6)	설정 일관성(1), 버전 정리(3), 장르 재미(6)	아니오	5/6/5	전환점 이유·설명 분산 / 행동 동기·전환점 이유·설명 분산 / 행동 동기·전환점 이유
p2a	핵심 규칙(2), 버전 정리(3), 장르 재미(6)	버전 정리(3), 장르 재미(6), 행동 동기(10)	버전 정리(3), 장르 재미(6), 행동 동기(10)	아니오	5/4/5	행동 동기·회차 끝 긴장 / 전환점 이유 / 전환점 이유·회차 끝 긴장
p2b	핵심 규칙(2), 버전 정리(3), 행동 동기(10)	장르 재미(6), 행동 동기(10), 전환점 이유(16)	설정 일관성(1), 장르 재미(6), 행동 동기(10)	아니오	4/4/4	전환점 이유 / 회차 끝 긴장 / 전환점 이유
p3a	연재 지속성(5), 장르 재미(6), 행동 동기(10)	연재 지속성(5), 장르 재미(6), 행동 동기(10)	설정 일관성(1), 연재 지속성(5), 장르 재미(6)	아니오	6/5/7	갈등의 크기·전환점 이유·설명 분산 / 갈등의 크기·전환점 이유 / 행동 동기·갈등의 크기·전환점 이유·설명 분산
p3b	설정 일관성(1), 버전 정리(3), 연재 지속성(5)	설정 일관성(1), 버전 정리(3), 연재 지속성(5)	설정 일관성(1), 버전 정리(3), 연재 지속성(5)	예	6/8/9	장르 재미·행동 동기·전환점 이유 / 장르 재미·행동 동기·갈등의 크기·전환점 이유·설명 분산 / 장르 재미·행동 동기·갈등의 크기·전환점 이유·회차 끝 긴장·설명 분산
p4a	설정 일관성(1), 연재 지속성(5), 행동 동기(10)	버전 정리(3), 연재 지속성(5), 행동 동기(10)	버전 정리(3), 연재 지속성(5), 행동 동기(10)	아니오	4/5/4	전환점 이유 / 갈등의 크기·전환점 이유 / 전환점 이유
p4b	버전 정리(3), 연재 지속성(5), 행동 동기(10)	버전 정리(3), 행동 동기(10), 인물 변화(13)	버전 정리(3), 연재 지속성(5), 행동 동기(10)	아니오	7/6/8	인물 변화·전환점 이유·결말 방향·주제 일관성 / 전환점 이유·결말 방향·주제 일관성 / 인물 변화·갈등의 크기·전환점 이유·결말 방향·주제 일관성

3회 모두 같은 샘플: 2/8. 목록 순서대로 뽑힌 실행: 24/24.

- 목록 앞쪽 항목의 답이 한 번 바뀌면 3가지가 바뀐다(F3). p1b는 버전 정리(목록 3번째)가 "아니오"가 되자 행동 동기가 밀려났고, p3a는 3회차에 설정 일관성(1번째)이 "아니오"가 되면서 행동 동기가 밀려났다.
- p2b는 3회의 3가지가 모두 달랐다. 행동 동기만 3회 모두 들어갔다.

대상 질문과 라벨

칸은 최종 답 / 먼저 고칠 3가지에 들어갔는지 / 근거를 확인하지 못해 "예"가 "아니오"로 바뀌었는지 순서다.

샘플	질문	임시 라벨	1회차	2회차	3회차	3회 모두 같은 답
p1a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오	예
p1b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오	예
p2a	motivation.reason	문제 없음	no / - / 아니오	no / 포함 / 아니오	no / 포함 / 아니오	예
p2b	motivation.reason	정보 부족	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오	예
p3a	versions.separated	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오	예
p3a	consistency.no_conflict	문제 없음	yes / - / 아니오	yes / - / 아니오	no / 포함 / 아니오	아니오
p3b	versions.separated	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오	예
p3b	consistency.no_conflict	문제 있음	no / 포함 / 아니오	no / 포함 / 아니오	no / 포함 / 아니오	예

샘플	질문	임시 라벨	1회차	2회차	3회차	3회 모두 같은 답
p4a	ending.decided	문제 없음	yes / - / 아니오	yes / - / 아니오	yes / - / 아니오	예
p4b	ending.decided	정보 부족	no / - / 아니오	no / - / 아니오	no / - / 아니오	예

임시 라벨	대상 건수(회차당)	1회차	2회차	3회차
문제 없음	5	예 4, 아니오 1	예 4, 아니오 1	예 3, 아니오 2
문제 있음	3	예 0, 아니오 3	예 0, 아니오 3	예 0, 아니오 3
정보 부족	2	예 0, 아니오 2	예 0, 아니오 2	예 0, 아니오 2
해당 없음	0	예 0, 아니오 0	예 0, 아니오 0	예 0, 아니오 0

- 10건 중 9건은 3회 모두 같은 답이다. p3a consistency.no_conflict 만 예/예/아니오로 바뀌었다.
- p2a motivation.reason 은 3회 모두 "아니오"로 라벨('문제 없음')과 어긋난다. 답은 흔들리지 않았지만 이유는 회차마다 달랐다. 아래 [사람이 검토해야 할 것](#) 참고.
- '문제 있음' 3건과 '정보 부족' 2건은 3회 모두 "아니오"였다.

반드시 찾아야 할 문제

괄호는 그 질문의 최종 답과, 라벨이 정한 필수 인용 가운데 실제로 단 수다.

샘플	문제	1회차	2회차	3회차
p1b	3년 전 죽었다는 테오의 기사 학교 학비를 아델이 마련하려 한다	찾음 (아니오, 2/2)	찾음 (아니오, 2/2)	찾음 (아니오, 2/2)
p2b	2화 서운을 구하기로 한 이유, 4~10화 회수인과 맞서기로 한 이유, 20화 수명 10년을 내준 이유가 메모에 없다	못 찾음 (아니오, 2/3)	못 찾음 (아니오, 1/3)	못 찾음 (아니오, 2/3)
p3b	흑의 무리의 첩자로 길러졌다는 설정과 누구의 제자도 된 적 없다는 설정이 함께 적혀 있다	못 찾음 (아니오, 0/2)	못 찾음 (아니오, 0/2)	못 찾음 (아니오, 0/2)
p3b	객잔 이름이 청운객잔과 흑비단객잔으로 엇갈린다	찾음 (아니오, 2/2)	찾음 (아니오, 2/2)	찾음 (아니오, 2/2)
p3b	어느 설정이 최종이고 어느 설정을 버렸는지 표시가 없다	못 찾음 (아니오, 0/2)	찾음 (아니오, 1/2)	못 찾음 (아니오, 0/2)
p4b	이야기가 도달할 지점(결말)이 메모에 없다	찾음 (아니오)	찾음 (아니오)	찾음 (아니오)

- p2b는 답은 3회 모두 "아니오"였지만 필수 인용 3개 중 2개, 1개, 2개만 달아 3회 모두 '못 찾음'이다.
- p3b의 첩자 모순은 3회 모두 필수 인용이 0개다. 버전 표시 없음은 2회차만 인용을 달았다.
- p3b의 객잔 이름은 3회 모두 필수 인용 2개를 달았다. 2026-10-01에는 반대편 근거로 제목과 인물 소개를 인용해 1/2였다. 이번에 G4가 통과로 바뀐 것은 이 차이 때문이다.

하면 안 되는 지적

회차별 적발 수: 1회차 3건, 2회차 3건, 3회차 1건. 회차당 대상은 10건이고, 그중 사람만 판단할 수 있는 것은 1건이다.

샘플	회차	금지 항목	설명	적발 내용
p2a	1	miso-hidden	작가가 일부러 숨긴 미소의 정체와 목적을 동기 누락이나 설정 충돌로 지적한다	motivation.reason: "아니오" 근거로 인용
p2a	2	miso-hidden	작가가 일부러 숨긴 미소의 정체와 목적을 동기 누락이나 설정 충돌로 지적한다	motivation.reason: "아니오" 근거로 인용
p2b	2	miso-hidden	작가가 일부러 숨긴 미소의 정체와 목적을 동기 누락이나 설정 충돌로 지적한다	motivation.reason: "아니오" 근거로 인용

샘플	회차	금지 항목	설명	적발 내용
p4a	1	many-culprits	여러 사람이 조금씩 관여했다는 의도적 설정을 전환점 이유 누락이나 설정 충돌로 지적한다	turning_points.why: "아니오" 근거로 인용
p4a	2	many-culprits	여러 사람이 조금씩 관여했다는 의도적 설정을 전환점 이유 누락이나 설정 충돌로 지적한다	turning_points.why: "아니오" 근거로 인용
p4a	3	many-culprits	여러 사람이 조금씩 관여했다는 의도적 설정을 전환점 이유 누락이나 설정 충돌로 지적한다	turning_points.why: "아니오" 근거로 인용
p4b	1	many-culprits	여러 사람이 조금씩 관여했다는 의도적 설정을 전환점 이유 누락이나 설정 충돌로 지적한다	turning_points.why: "아니오" 근거로 인용

- 자동 적발은 금지 문장이 해당 질문의 "아니오" 근거로 인용됐는지를 센 의심 건이다. 실제로 하면 안 되는 지적인지는 사람이 확인해야 한다.
- p2a-p2b의 miso-hidden 3건은 조연 미소의 숨긴 목적을 행동 동기 "아니오"의 근거로 든 경우다. p2a 3회차는 답은 "아니오"였지만 이유가 결말의 장부 소각이어서 이 문장을 인용하지 않았다.
- p4a-p4b의 many-culprits 4건은 turning_points.why "아니오"의 근거에 "한 사람의 범행이 아니다."가 든 문장이 들어간 경우다. 이유는 네 번 모두 그 사실을 어떤 증거로 입증하는지가 메모에 없다는 것이었고, 여러 사람이 관여했다는 설정 자체를 문제 삼지는 않았다.
- 사람만 판단할 수 있는 p4b invented-ending 은 자동 적발 대상이 아니다. 3회의 이유는 모두 결말이 메모에 적혀 있지 않다는 것이었다.

쌍 비교

칸은 달라진 질문 수 / 비교한 질문 수다. 대상 질문과 라벨의 mayAlsoChange(바꾼 부분 때문에 함께 달라질 수 있는 질문)는 비교에서 뺐다.

쌍	1회차	2회차	3회차
p1	2/19 (versions.separated 아니오→예, cliffhanger.hooks 아니오→예)	0/19	0/19
p2	3/18 (genre_fit.core_fun 아니오→예 주관, turning_points.why 예→아니오, cliffhanger.hooks 아니오→예)	2/18 (versions.separated 아니오→예, cliffhanger.hooks 예→아니오)	3/18 (consistency.no_conflict 예→아니오, versions.separated 아니오→예, cliffhanger.hooks 아니오→예)
p3	2/21 (stakes.cost 아니오→예, exposition.not_dumped 아니오→예)	1/21 (exposition.not_dumped 예→아니오)	1/21 (cliffhanger.hooks 예→아니오)
p4	2/20 (consistency.no_conflict 아니오→예, versions.separated 예→아니오)	2/20 (longevity.next 아니오→예, stakes.cost 아니오→예)	1/20 (stakes.cost 예→아니오)

회차별 합계: 1회차 9건, 2회차 5건, 3회차 5건.

달라진 19건 모두에서, 그 쌍의 두 메모 가운데 적어도 한쪽이 같은 질문에 3회 사이 다른 답을 냈다(버전 정리, 회차 끝 긴장, 설명 분산, 갈등의 크기, 설정 일관성, 전환점 이유, 장르 재미, 연재 지속성). A는 3회 모두 한 답, B는 3회 모두 다른 답인 질문은 없다. 그래서 쌍 사이의 차이는 실행마다의 흔들림만으로도 설명된다. 다만 메모를 바꾼 영향이 없다고 입증한 것은 아니다. 기준선 문서 F6이 가릴 수 없다고 한 두 원인(메모를 바꾼 영향, 실행마다 생기는 흔들림)은 이 자료로도 완전히 가를 수 없다.

관문 판정 (회차별): 다섯 개를 모두 통과한 회차 없음

관문	기준	1회차	2회차	3회차
G1	8건 모두 stage === "done"	8/8 통과	8/8 통과	8/8 통과

관문	기준	1회차	2회차	3회차
G2	'문제 있음' 3건 모두 no	3/3 통과	3/3 통과	3/3 통과
G3	'문제 없음' 5건 중 yes 4건 이상	4/5 통과 (p2a motivation.reason=no)	4/5 통과 (p2a motivation.reason=no)	3/5 실패 (p2a motivation.reason=no, p3a consistency.no_conflict=no)
G4	mustFind 6건 중 found 3건 이상	3/6 통과	4/6 통과	3/6 통과
G5	mustNotFlag hits 합계 1 이하	3 실패	3 실패	1 통과

- G1과 G2는 3회 모두 통과했다.
- G4는 3회 모두 통과했다(3건, 4건, 3건). 2026-10-01에는 2건으로 실패했다.
- G5는 1·2회차에 3건으로 실패하고 3회차에 1건으로 통과했다. 2026-10-01에는 2건으로 실패했다.
- G3은 1·2회차에 통과하고 3회차에 실패했다. p2a 행동 동기에 p3a 설정 일관성이 더해져 "예"가 3건이 됐다.
- 같은 설정으로 1회만 졌다면 어느 회차를 뺐었느냐에 따라 실패하는 관문이 달라졌을 것이다. 1회 측정으로 관문 통과 여부를 판단하면 안 된다.
- 관문 기준과 라벨은 바꾸지 않았다. 관문을 반복 측정에 어떻게 적용할지(매 회차 통과, 3회 중 2회 통과 등)는 정해진 기준이 없어서 회차별 결과만 적었다.

소요 시간, 비용, 후처리

회차	성공	소요 합계	중앙값	범위	비용 합계	1회 평균	원본 인용 / 원문에 없는 인용 / 후처리로 바뀐 답
1회차	8/8	3,158초	265초	207~1,219초	\$0.1571	\$0.0196	690 / 2 / 0
2회차	8/8	2,008초	257초	223~271초	\$0.1436	\$0.0179	710 / 1 / 0
3회차	8/8	2,239초	286초	242~322초	\$0.1577	\$0.0197	750 / 1 / 0
전체	24/24	7,405초	266초	207~1,219초	\$0.4584	\$0.0191	2,150 / 4 / 0

비용(표준 요금): 합계 \$0.4584, 1회 평균 \$0.0191, 중앙값 \$0.0190, 최대 \$0.0260. 10분을 넘긴 실행: 1건.

샘플	회차	결과	소요(초)	원본 인용	원문에 없는 인용	후처리로 바뀐 답	질문 누락	출력 토큰(그중 추론)	비용
p1a	1	성공	367	86	0	0	0	43,760 (35,249)	\$0.0229
p1a	2	성공	249	94	0	0	0	32,438 (23,541)	\$0.0163
p1a	3	성공	275	99	0	0	0	37,631 (28,896)	\$0.0189
p1b	1	성공	270	84	0	0	0	37,251 (28,461)	\$0.0189
p1b	2	성공	271	88	0	0	0	37,300 (28,129)	\$0.0187
p1b	3	성공	322	99	0	0	0	42,600 (34,174)	\$0.0214
p2a	1	성공	373	87	0	0	0	51,423 (42,572)	\$0.0260
p2a	2	성공	267	90	1	0	0	39,146 (30,487)	\$0.0197
p2a	3	성공	250	94	0	0	0	35,164 (26,323)	\$0.0177
p2b	1	성공	260	94	0	0	0	37,564 (29,167)	\$0.0191
p2b	2	성공	264	98	0	0	0	39,718 (30,941)	\$0.0199
p2b	3	성공	255	112	0	0	0	40,481 (31,648)	\$0.0203
p3a	1	성공	211	83	0	0	0	31,477 (22,920)	\$0.0160
p3a	2	성공	227	76	0	0	0	31,850 (23,936)	\$0.0160

샘플	회차	결과	소요(초)	원본 인용	원문에 없는 인용	후처리로 바뀐 답	질문 누락	출력 토큰(그중 추론)	비용
p3a	3	성공	298	90	0	0	0	39,797 (31,467)	\$0.0200
p3b	1	성공	1,219	74	0	0	0	42,262 (33,921)	\$0.0214
p3b	2	성공	270	77	0	0	0	39,107 (30,830)	\$0.0196
p3b	3	성공	301	87	0	0	0	42,112 (33,859)	\$0.0211
p4a	1	성공	251	97	2	0	0	35,718 (27,452)	\$0.0181
p4a	2	성공	237	98	0	0	0	34,421 (26,407)	\$0.0173
p4a	3	성공	242	95	0	0	0	36,166 (28,188)	\$0.0182
p4b	1	성공	207	85	0	0	0	28,944 (20,737)	\$0.0147
p4b	2	성공	223	89	0	0	0	31,850 (23,847)	\$0.0160
p4b	3	성공	296	74	1	0	0	40,183 (32,287)	\$0.0202

- 느린 실행: p3b 1회차가 1,219초 걸렸다. 출력 토큰은 42,262개로 다른 실행과 같은 수준이고, 응답 본문의 `created_at` 과 `completed_at` 차이가 1,218초다. 느려진 구간은 우리 쪽 대기나 네트워크가 아니라 OpenAI 쪽 처리 시간이다.
- 2026-10-01 측정의 느린 2건도 같다. 벽시계 1,124초와 1,218초에 응답에 찍힌 시간이 1,119초와 1,213초였다. [LUNA-2026-10-01.md](#)는 시간이 길어진 원인이 기록에 없다고 적었는데, 여기까지는 좁힐 수 있다. 왜 그런지는 응답에 없다.
- 두 측정을 합치면 32건 중 3건이 약 20분 걸렸다.

원문에 없는 인용

샘플	회차	위치	질문	인용
p2a	2	answers	early_pace.goal_early	한결의 수명은 1년 줄어 있다.
p4a	1	answers	supporting.role	이장은 요양원에서 은서를 만나
p4a	1	setting.events	-	이장은 요양원에서 은서를 만나
p4b	3	answers	genre_fit.core_fun	이장은 그 애는 도망간 게 아니라 돈을 돌려주러 갔다고 말하고 잠든다.

네 개 모두 앱이 버려서 화면에 나오지 않았다. 네 경우 모두 같은 답이나 항목에 다른 인용이 남아 있어서, 답이 바뀌거나 설정 정리 항목이 빠지지 않았다.

2026-10-01의 1회 결과와 비교

판정 프롬프트, 스키마, 규칙이 같으므로 2026-10-01의 1회를 네 번째 반복으로 볼 수 있다.

샘플	네 번 모두 같은 답 (23개 중)	이번 3회는 같고 2026-10-01만 다름	이번 3회 안에서 갈림	먼저 고칠 3가지가 네 번 모두 같은가
p1a	21	0	2	예
p1b	21	0	2	아니오
p2a	18	2	3	아니오
p2b	18	0	5	아니오
p3a	20	1	2	아니오
p3b	20	0	3	예
p4a	19	1	3	아니오
p4b	21	0	2	아니오

샘플	네 번 모두 같은 답 (23개 중)	이번 3회는 같고 2026- 10-01만 다름	이번 3회 안에서 같림	먼저 고칠 3가지가 네 번 모두 같은가
합계 (184칸)	158	4	22	2/8

- 이번 3회는 같은데 2026-10-01만 다른 답이 4칸 있다. p2a consistency.no_conflict (그때 아니오, 이번 예 3회), p2a versions.separated (그때 예, 이번 아니오 3회), p3a stakes.cost (그때 예, 이번 아니오 3회), p4a longevity.next (그때 예, 이번 아니오 3회)다.
- 3회가 같아도 네 번째에서 달라질 수 있다. 3회 일치는 안정적이라는 근거이지 보장이 아니다.

F1~F7로 본 이번 결과

사례	2026-10-01 (max, 1회)	이번 3회
F1 동기 정보 부족을 짐작으로 채움(p2b)	발생하지 않음	3회 모두 발생하지 않음("아니오"). p2a는 3회 모두 "아니오"로 '문제 없음' 라벨과 불일치
F2 판단과 무관한 인용 통과	예상 근거 밖 인용이 대상 10건 중 8건	구조는 그대로다. 예상 근거 밖 인용이 대상 10건 중 6건, 9건, 6건. 새 사례로, p4a 3회차와 p4b 3회는 댐 연도 문장을 설정 일관성 "예"의 근거로 인용했다
F3 먼저 고칠 3가지가 목록 순서로 정해짐	8/8건	24/24건. 빨강 4~9개. p4b 결말이 3회 모두 빨강인데 빠짐. 같은 메모에서도 3가지가 달라져, 3회 모두 같은 샘플은 2/8
F4 근거 확인 실패가 결함처럼 표시되는 구조	실측 0건	실측 0건. 원문에 없는 인용 4개는 다른 인용이 남아 답이 바뀌지 않음
F5 메모에 없는 것과 잘못된 것이 같은 빨강	p2b, p4b	p2b와 p4b 각 3회, 6건 모두 빨강
F6 쌍 사이 무관 질문 흔들림	2쌍, 합계 3건	회차별 9건, 5건, 5건. 19건 모두 그 쌍의 한쪽 메모가 같은 질문에서 3회 사이에 답이 같린 경우다. 메모를 바꾼 영향과는 여전히 완전히 가를 수 없다
F7 합성 샘플의 의도하지 않은 결함	p4 댐 연도는 p4a에서만 지적	p2 빛 출처는 6건 모두 설정 일관성에서도 설정 정리에서도 지적하지 않음. p4 댐 연도는 6건 중 1건(p4a 1회차)만 지적

사람이 검토해야 할 것

기준선 문서와 [LUNA-2026-10-01.md](#)의 목록이 그대로 적용된다. 이번에 추가로 볼 것은 다음과 같다. 이 문서는 라벨, 질문, 프롬프트를 바꾸지 않았다.

대상	무엇을 정해야 하나
motivation.reason 질문과 p2a 라벨	질문 문장은 "주요 인물의 중요한 선택마다 이유가 적혀 있는가?"이다. p2a는 3회 모두 "아니오"였다. LUNA-2026-10-01.md 의 세 번을 합치면 여섯 번 연속이다. 1·2회차의 이유는 조연(서윤, 미소)의 숨긴 동기가 메모에 없다는 것이고, 3회차의 이유는 결말에서 한결이 장부를 불태우는 선택의 목적이 적혀 있지 않다는 것이다. 정할 것은 세 가지다. 질문이 주인공의 선택만 묻는지 주요 인물 전체를 묻는지, 작가가 숨긴다고 밝힌 동기를 공백으로 불지, 라벨이 든 세 선택 말고 결말의 장부 소각도 이유가 필요한 선택으로 불지다. 이번 24건은 8개 샘플 모두에서 "아니오"였다. 지금은 동기 문장이 있는 메모(p2a)와 지운 메모(p2b)를 가르지 못한다.
versions.separated 와 '해당 없음'	버리거나 바꾼 설정이 없는 메모 6개(p1a, p1b, p2a, p2b, p4a, p4b)의 18건 중 14건이 "아니오"였고, 6개 중 3개에서는 답도 같렸다. 목록 3번째 항목이라 그 14건 모두 먼저 고칠 3가지에 들어갔다. CRITERIA.md 2절의 '해당 없음'에 해당하는 경우로 보인다. 이런 메모에서 이 질문을 어떻게 판정할지(예로 불지, 판정하지 않을지) 정해야 한다.
p3a consistency.no_conflict 3회차	2화의 "장부가 객잔 지하에 있다는 걸 알아낸다"와 3화의 "장부 대신 마 노인의 인장이 찍힌 거래 문서를 발견한다"를 어긋나는 설정으로 봤다. 오답인지 확인한다.

대상	무엇을 정해야 하나
cliffhanger.hooks , exposition.not_ dumped , stakes.cost	같은 근거를 두고 답이 갈린다. 초반 몇 화에만 절단 지점이 정해져 있으면 "예"인지, 규칙을 어느 장면에서 알릴지 적혀 있지 않으면 "아니오"인지, 실패의 대가가 감정적 손실뿐이어도 "예"인지, 질문의 기준선을 문장으로 정해야 한다.
한 가지 공백의 귀속	p2에서 수명 계약이 어떻게 작동하는지 적혀 있지 않다는 공백이 실행에 따라 핵심 규칙, 전환점 이유, 설정 일관성에 붙었다. 같은 사실을 어느 질문에서 지적할지에 대한 규칙이 필요하지 정한다(기준선 문서 F6의 제안과 같다).
p3b의 첩자 모순	"소운은 흑의 무리의 첩자로 길러졌다가 배신한다."와 "그 뒤로 누구의 제자도 된 적이 없다."를 3회 모두 어긋난다고 보지 않았다(2026-10-01 측정도 같다). 흔들림이 아니라 반복되는 농침이다. 이 두 문장이 실제로 양립할 수 없는지, 라벨이 요구하는 수준이 맞는지 확인한다.
p4의 댐 연도(F7)	의도하지 않은 결함을 p4a는 3회 중 1회만 짚었고 p4b는 3회 모두 짚지 않았다. p4a 3회차와 p4b 3회는 연도 문장을 어긋나지 않는다는 근거로 인용했다. 샘플을 고칠지, 라벨에 반영할지는 기준선 문서 F7의 결정 사항 그대로다.
p4의 many-culprits 적발 4건	금지 문장을 인용했지만 이유는 입증 과정의 공백이었다. 하면 안 되는 지적으로 셀지 정한다. G5의 통과 여부가 여기에 달려 있다.
p4b invented-ending	사람만 판단할 수 있다. 3회의 이유와 방향이 결말을 지어내지 않았는지 확인한다.
관문을 반복 측정에 적용하는 방법	회차마다 실패하는 관문이 달랐다. 매 회차 통과를 요구할지, 3회 중 몇 회를 요구할지 정해야 한다.

review.csv 는 552행이다(1순위 34행, 2순위 96행, 3순위 43행, 4순위 29행, 5순위 350행). 1순위부터 본다.

실제 메모로 최종 확인할 때 (이번에도 하지 않음)

기준선 문서의 조건(동의와 보관, 처음 보는 메모, 구성, 라벨 먼저, 반복 실행, 보고 분리)을 그대로 따른다. 이번에도 실제 메모를 가져오거나 진단하지 않았다.

이번 측정으로 달라진 점은 두 가지다.

- **반복 실행이 꼭 필요하다.** 같은 메모에서도 23개 질문 중 2~5개의 답이 실행마다 달라졌으므로, 실제 메모도 1회 결과로 판정하지 말고 --repeat 3 으로 돌려서 3회 모두 같은 답만 안정된 판정으로 읽는다.
- **비용과 시간:** 1회 평균 \$0.0191이고 보통 3분 반에서 6분 걸린다. 메모 5개를 3회씩 돌리면 15회, 표준 요금으로 약 \$0.29다. 시간은 1시간 10분 안팎이고, 약 20분짜리 실행이 섞이면 그만큼 늘어난다.

웹 성능 측정 (2026-10-02)

배포 앱에서 로그인 없이 열리는 두 화면을 Lighthouse로 잰 결과다. 진단의 판정 품질 평가([CRITERIA.md](#))와는 별개이고, 진단에 걸리는 시간(보통 5분)도 여기에 들어 있지 않다.

화면과 기기마다 3회씩만 잰고, 실행마다 값이 크게 같렸다. 중앙값만 보지 말고 범위를 함께 봐야 한다.

측정 조건

- 도구: Lighthouse 13.5.0, 헤드리스 Chrome 154. 작성자 맥에서 실행했다(Lighthouse 벤치마크 지수 4,075~4,655).
- 명령: `bunx lighthouse <주소> --only-categories=performance --chrome-flags="--headless=new"`. 데스크톱은 `--preset=desktop` 을 더했다.
- 가정: 모바일은 Lighthouse 기본값이다(느린 4G: 왕복 지연 150ms, 내려받기 약 1.5Mbps, CPU 4배 감속을 모의 계산). 데스크톱은 왕복 지연 40ms에 감속이 없다.
- 대상: `https://side-project-gamma.vercel.app/login` 과 `https://side-project-gamma.vercel.app/demo`. `/demo` 는 예시 리포트(`/reports/<id>`)로 리다이렉트되며, 그 시간이 값에 들어 있다.
- 표본: 화면 2개 × 기기 2종 × 3회를 12회를 계획해 12회를 실행했고, 실패는 0회다. 진단은 실행하지 않았다.
- 원자료(JSON 12개)는 커밋하지 않는 로컬 작업 기록 `.omo/evidence/perf-repeat/lighthouse/` 에 있다.

결과 (중앙값, 괄호는 3회의 범위)

화면	기기	Performance 점수	LCP	CLS	TBT
로그인 (<code>/login</code>)	모바일	75 (66~99)	12.1초 (1.8~12.7초)	0.000 (0~0.027)	0ms (0~7ms)
로그인 (<code>/login</code>)	데스크톱	100 (87~100)	0.5초 (0.5~2.4초)	0.000 (0~0)	0ms (0~0ms)
예시 리포트 (<code>/demo</code>)	모바일	98 (67~99)	1.8초 (1.5~13.0초)	0.034 (0.005~0.034)	4ms (4~5ms)
예시 리포트 (<code>/demo</code>)	데스크톱	91 (83~98)	2.0초 (0.4~2.4초)	0.001 (0.001~0.085)	0ms (0~0ms)

읽는 법

- TBT와 CLS는 12회 모두 낮다. TBT는 7ms 이하, CLS는 0.085 이하다.
- LCP와 점수는 실행마다 같린다. 모바일 6회 중 3회(로그인 2회, 예시 리포트 1회)는 LCP가 12~13초로 계산됐고, 나머지 3회는 1.5~1.8초였다. 3회로는 어느 쪽이 중앙값이 될지가 운에 달려 있어서, 두 화면의 모바일 중앙값 차이(12.1초와 1.8초)를 화면 차이로 읽으면 안 된다.
- 원인으로 보이는 것(추정): 전송량 2.2MB 가운데 2.0MB가 Pretendard 가변 폰트 파일 하나다 (`PretendardVariable.woff2` , 요청 우선순위 High). LCP 요소는 두 화면 모두 본문 글자다. 약 1.5Mbps를 가정하면 이 폰트를 받는 데 11초쯤 걸리고, Lighthouse가 글자 표시를 폰트 뒤로 계산한 실행에서 LCP가 12초대가 된다. 감속 없이 실제로 관측된 LCP는 12회 모두 0.9~2.4초였다.
- 느린 망에서 실제 사용자가 글자를 언제 보느냐는 이 측정으로 확정할 수 없다. 폰트는 `font-display` 검사를 통과했다.

고치지 않은 것 (후속 제안)

앱은 바꾸지 않았다. 폰트를 서브셋으로 나눠 필요한 글자만 받게 하면 전송량이 크게 줄 것으로 보인다. 효과는 재지 않았다.

판정 품질 평가

기획 메모 진단의 판정 품질을 합성 메모로 재는 도구다. 기준은 [CRITERIA.md](#)에 있다.

폴더

경로	내용
eval/samples/*.json	모델 입력. 앱이 받는 장르, 메모, 참고작만 있다
eval/labels/*.json	사람 검토 전 임시 라벨. 모델에는 넣지 않는다
eval/results/<실행 시각>/	실행 결과. 리포트 DB에는 넣지 않는다
scripts/eval/run.mts	실행기. 앱과 같은 진단 경로(<code>diagnoseDetailed</code>)를 부른다
scripts/eval/score.mts	채점기. 모델을 부르지 않는다
scripts/eval/lib.ts, lib.test.ts	집계 로직과 그 테스트

실행 방법

```
# 1. 집계 로직 테스트 (모델 호출 없음)
bun run test:eval

# 2. 드라이런: 가짜 응답으로 저장과 집계만 확인 (모델 호출 없음, 임시 폴더에 저장)
bun run eval -- --dry-run --repeat 3
bun run eval:score -- <출력된 폴더>

# 3. 실제 실행: 샘플 8개를 1회씩, 순차로 (모델 호출 8회)
bun run eval -- --samples all --repeat 1 --max-calls 8
bun run eval:score -- eval/results/<실행 시각>

# 반복 일관성: 같은 샘플을 3회씩 (모델 호출 24회라 상한을 직접 올려야 한다)
bun run eval -- --samples all --repeat 3 --max-calls 24
```

- 일부 샘플만 돌리려면 `--samples p1a,p1b` 처럼 쓴다.
- 모델과 추론 강도는 앱과 같이 `OPENAI_MODEL`, `OPENAI_EFFORT` 로 정해진다(기본값 `gpt-6-luna`, `max`). API 키는 `.env.local` 의 `OPENAI_API_KEY` 를 읽는다.
- `--max-calls` 는 실제 과금 상한이다. 모델 호출 한 번이 곧 과금 한 번이다.
- 모델 호출이 실패하면 재시도하지 않고 멈춘다(종료 코드 2). 원인은 해당 실행의 `meta.json` 에 있다.
- Claude 기준선은 `BASELINE-2026-09-30.md` 에 남아 있다.

결과 파일

실행 하나(`eval/results/<실행 시각>/<샘플>/run-<회차>/`)마다 다음을 남긴다.

파일	내용
input.json	모델에 넣은 메모와 프롬프트 해시
model-output.json	모델 응답을 질문·항목 순서 배열로 바꾼 것(앱 후처리 전)
api-response.json	OpenAI Responses API 응답 본문에서 output을 뺀 것(usage 포함)

파일	내용
report.json	앱 후처리를 거친 최종 리포트. 후처리가 거부하면 null
postprocess.json	원문에 없는 인용, 후처리로 바뀐 답, 질문 누락·중복, 먼저 고칠 3가지 분석
meta.json	성공·실패 단계, 오류, 소요 시간, 모델 설정, 응답이 보고한 모델(apiModel), 응답 ID(responseId), 토큰 사용량(usage), 표준 요금 비용(costUsd)

폴더 맨 위에는 run-info.json (설정, 프롬프트·규칙 해시, git 커밋)과 runs.jsonl (실행별 한 줄 요약)이 있다. 채점기를 돌리면 summary.md, summary.json, review.csv (사람 검토표)가 생긴다.

scripts/diagnose.mts --raw 는 최종 리포트만 출력하고 모델 원본 응답은 내놓지 않는다. 원본 응답이 필요하다면 이 도구를 쓴다.